



Preditiva.ai

# Fundamentos de ETL para Análise de Dados O que é ETL?

# O que é ETL e por que é essencial para análise de dados




Preditiva.ai

## Introdução

Com o avanço da tecnologia e o aumento das fontes de dados, as empresas enfrentaram o **desafio de centralizar** informações dispersas em sistemas diferentes.

Dados provenientes de bancos de dados, planilhas, sistemas transacionais e outras fontes precisavam ser integrados para fornecer uma visão consolidada do negócio.



Quais os padrões de comportamento dos clientes?

Como está a eficiência das campanhas de marketing?

Como estamos atendendo às necessidades dos clientes?


# O que é ETL e por que é essencial para análise de dados



Preditiva.ai


## Introdução

Foi nesse contexto que surgiu o termo **ETL**. A necessidade de extrair dados de múltiplas fontes, transformá-los para garantir qualidade e consistência, e carregá-los em um repositório central para análise tornou o ETL essencial. Esse processo permite que as organizações obtenham insights valiosos a partir de dados brutos, melhorando a tomada de decisões e impulsionando a eficiência operacional.




**Extract**

Extração dos dados das origens



**Transform**

Transformação dos dados visando limpeza, consistência e qualidade dos dados para que esteja pronto para consumo



**Load**

Carga dos dados no banco de dados de destino

# O que é ETL e por que é essencial para análise de dados

## Introdução




Preditiva.ai

### Extract (Extração):

Nesta fase, os dados são extraídos de diversas fontes de dados, como bancos de dados relacionais (SQL RDBM), sistemas transacionais (ERP, CRM), e arquivos (CSV, Excel, TXT).

A principal preocupação nesta etapa é garantir que os dados sejam **coletados de forma completa e precisa**, para que possam ser transformados e analisados posteriormente.



# O que é ETL e por que é essencial para análise de dados



Preditiva.ai


## Introdução

Transform (Transformação):

Os dados extraídos são então transformados para melhorar a qualidade, consistência e utilidade.

Esse processo inclui tarefas como limpeza de dados, remoção de duplicatas, padronização de formatos, enriquecimento com dados adicionais e agregações necessárias para análise.

**O objetivo é transformar os dados brutos em informações de qualidade**, prontas para serem consumidas pelos sistemas de análise e relatórios.



# O que é ETL e por que é essencial para análise de dados




Preditiva.ai

## Introdução

Load (Carga):

Finalmente, os dados transformados são carregados em um repositório central, como um Data Warehouse ou Data Lake.

Essa etapa assegura que os dados estejam **disponíveis para análise e tomada de decisão**, permitindo a geração de insights valiosos a partir de grandes volumes de dados.



# O que é ETL e por que é essencial para análise de dados



Preditiva.ai

## As ferramentas

Com a evolução da tecnologia, diversas ferramentas de ETL têm surgido no mercado, oferecendo soluções avançadas e eficientes para integração e transformação de dados.

Estas ferramentas variam desde opções básicas e acessíveis até plataformas robustas e sofisticadas, capazes de lidar com grandes volumes de dados e integrações complexas.





**Preditiva.ai**





Preditiva.ai

# Fundamentos de ETL para Análise de Dados Power Query

# Power Query


## O que é?

O Power Query é um mecanismo de transformação e preparação de dados. O Power Query vem com uma interface gráfica para obter dados de fontes e um Editor do Power Query para aplicar transformações.

Como o mecanismo está disponível em muitos produtos e serviços, o destino no qual os dados serão armazenados depende de onde o Power Query foi usado. Usando o Power Query, você pode executar o **processamento ETL (extrair, transformar e carregar)** com diversas fontes e tipos de dados.



Preditiva.ai




# Power Query com Microsoft Excel

## Sobre a Ferramenta



Na Barra de Menu superior no Excel, devemos acessar a opção "**Dados**".

Acessando a opção **Obter Dados** podemos visualizar as opções disponíveis do Power Query no Excel.



# Power Query com Microsoft Excel

## Limitações e Disponibilidade



As versões do Microsoft Excel que possuem o Power Query disponível e a relação de conectores disponíveis pode ser encontrado na [documentação da microsoft](#).

| Versões Excel                   | Power Query                                                                          |
|---------------------------------|--------------------------------------------------------------------------------------|
| Office 2016 + Para Windows      |   |
| Excel for Microsoft 365 for Mac |   |
| Excel 2019 for Mac              |   |
| Excel for Android and iOS       |  |



**Preditiva.ai**



Preditiva.ai

# Fundamentos de ETL para Análise de Dados


## Tipos de Dados

# Tipos de Dados

## O que são Tipos de Dados?



**Tipos de dados** são as categorias que definem a forma como um dado é processado, armazenado e analisado. A correta identificação e manipulação dos tipos de dados são essenciais para a qualidade dos dados, performance do processamento e precisão das análises.



# Tipos de Dados

## Principais Tipos de Dados



Entender os tipos de dados é **crucial no ETL** porque cada tipo tem suas peculiaridades que influenciam como você manipula, transforma e armazena informações.

| Tipo de Dado                 | Definição                                                                                               | Exemplos                          |
|------------------------------|---------------------------------------------------------------------------------------------------------|-----------------------------------|
| Inteiro (int)                | Tipo de dado numérico para números sem frações                                                          | -707, 0, 707                      |
| Ponto Flutuante (float)      | Tipo de dado numérico para números com frações (com virgula)                                            | 707.07, 0.7, 707.00               |
| Caractere (char)             | Letra, dígito, símbolo de pontuação, símbolo ou espaço em branco                                        | a, 1, !                           |
| Texto (str ou text)          | Sequência de caracteres, dígitos ou símbolos                                                            | hello, +1-999-666-3333            |
| Booleano (bool)              | Valores verdadeiro ou falso                                                                             | 0 (falso), 1 (verdadeiro)         |
| Tipo Enumerado (enum)        | Conjunto pequeno de valores únicos predefinidos (textuais ou numéricos)                                 | rock (0), jazz (1)                |
| Array                        | Lista com um número de elementos em uma ordem específica                                                | rock (0), jazz (1), blues (2), .. |
| Data (date)                  | Data no formato AAAA-MM-DD (sintaxe ISO 8601)                                                           | 2021-09-28                        |
| Hora (time)                  | Hora no formato hh:mm<br>para a hora do dia, tempo desde um evento, ou intervalo de tempo entre eventos | 12:00:59                          |
| Data e Hora (datetime)       | Data e hora juntas no formato AAAA-MM-DD hh:mm                                                          | 2021-09-28 12:00:59               |
| Carimbo de Tempo (timestamp) | Número de segundos que passaram desde a meia-noite (00:00:00 UTC), 1º de janeiro de 1970 (tempo Unix)   | 1632855600                        |



# Tipos de Dados

## A Importância dos Tipos de Dados



Tipos de dados incorretos podem levar a erros de cálculo, quebras durante transformações e falhas de carregamento. Por exemplo:

- Perda de precisão numérica ao converter tipos de ponto flutuante para inteiro.
- Erros de data ao interpretar formatos de data diferentes.
- Distorção de informações ao tratar campos textuais como numéricos.
- Tipos de dados incompatíveis ao realizar operações de união (joins) podem resultar em conjuntos de dados incompletos ou incorretos.
- Comparações entre tipos de dados diferentes (por exemplo, strings e números) podem levar a resultados inesperados.
- Entre outros...



**Preditiva.ai**



Preditiva.ai

# Fundamentos de ETL para Análise de Dados

## Entendendo as fontes de dados

# Fontes de Dados

## O que é?

Uma fonte de dados se trata de qualquer **localização ou recurso** de onde os dados **podem ser extraídos** para uso em análises e processos de negócios. Isso inclui **bancos de dados, arquivos, APIs, sistemas de armazenamento em nuvem** e muito mais.

No contexto de ETL, as fontes de dados são o ponto de partida crucial. Compreender suas fontes de dados é essencial para garantir que os dados sejam transformados e carregados de forma acurada e confiável para que sejam úteis na tomada de decisões.



# Fontes de Dados

## Estruturas de Dados


### Estruturados

Dados estruturados são aqueles que seguem um modelo fixo ou esquema. Esses dados são facilmente inseridos, consultados, atualizados, organizados e visualizados na forma de linhas e colunas. Possuem tipos de dados definidos para cada coluna (como inteiro, decimal, texto, etc.)




### Semiestruturados

Os dados semiestruturados são uma combinação dos dados estruturados e não estruturados. Eles são organizados, mas não seguem uma estrutura rígida como os dados estruturados. Em vez disso, eles têm um formato predefinido que permite a consulta e análise.



### Não-estruturados

Dados não-estruturados são informações que não possuem um formato predefinido ou organização, o que os torna difíceis de coletar, processar e analisar automaticamente. Eles compreendem a maior parte dos dados existentes no ambiente digital.



# Fontes de Dados

## Formatos mais comuns



### Arquivos “flat”

#### Exemplos

CSV, TXT, Excel.

#### Características

Simples, amplamente utilizados, fáceis de exportar e importar. Ideal para dados que não requerem operações complexas de banco de dados.

#### Tipo

Semiestruturado

### Bancos de Dados Relacionais

MySQL, PostgreSQL, SQL Server.

Bancos de dados relacionais são altamente estruturados e seguem um esquema rigoroso com definições explícitas de tabelas, colunas, tipos de dados e relações.

Estruturado

### APIs e Dados Web

JSON, XML, HTML, Tweets.

Permite acesso a dados dinâmicos e em tempo real da internet, como redes sociais, serviços financeiros, meteorológicos, etc.

Semiestruturado e  
Não-Estruturados



**Preditiva.ai**



Preditiva.ai

# Fundamentos de ETL para Análise de Dados

## Fundamentos de Limpeza de Dados




# Limpeza de Dados

## O que é?




A limpeza de dados faz parte da etapa de Transformação (ETL) e trata-se do processo de detectar e corrigir (ou remover) registros corrompidos ou imprecisos de um conjunto de dados.



Extract

Extração dos dados das origens



Transform

Transformação dos dados visando limpeza, consistência e qualidade dos dados para que esteja pronto para consumo



Load

Carga dos dados no banco de dados de destino

# Limpeza de Dados

## Qualidade de Dados



Para maximizar a qualidade dos dados, precisamos entender **seis aspectos importantes** deste processo. São eles:

### Compleitude

Dados completos fornecem um quadro completo e preciso para análises.

### Consistência

Dados consistentes são necessários para uma visão completa e comparação de múltiplas fontes.

### Precisão

Dados precisos reduzem a possibilidade de erro nas decisões.

### Validade

Dados devem seguir regras e formatos predefinidos.

### Unicidade

Não deveríamos trabalhar com réplicas/duplicidades de registros.

### Integridade

Relacionamentos entre dados devem ser mantidos corretamente.

# Limpeza de Dados

## Principais Problemas



- **Dados Duplicados:** Registros que aparecem mais de uma vez no dataset.
- **Dados Faltantes/Inconsistentes:** Campos vazios ou com valores que não fazem sentido no contexto do dataset.
- **Erros de Formatação:** Dados precisos reduzem a possibilidade de erro nas decisões.
- **Valores Inválidos:** Dados que não se encaixam nos critérios esperados.
- **Erros de Entrada de Dados:** Erros humanos durante a inserção de dados introduzem inconsistências e imprecisões nos dados.



**Preditiva.ai**



Preditiva.ai

# Fundamentos de ETL para Análise de Dados

## Manipulação de Strings

# Manipulação de Strings

## O que é?

A manipulação de strings envolve a **modificação** e **padronização** de dados textuais para garantir consistência e precisão. Garantindo que todos os dados textuais sigam o mesmo formato, facilitando a análise e a integração de dados.



## Transformações Comuns

- **Conversão de Maiúsculas/Minúsculas:** Converte todo o texto em letras maiúsculas ou minúsculas.
- **Remoção de Espaços:** Remove espaços em branco no início, no final ou duplicados dentro da string.
- **Substituição de Caracteres:** substitui caracteres específicos por outros.
- **Divisão de Strings(Split):** Divide uma string em uma lista de substrings com base em um delimitador.
- **Concatenar Strings:** Junta duas ou mais strings em uma única string.
- **Extração de Substrings:** Erros humanos durante a inserção de dados introduzem inconsistências e imprecisões nos dados.
- **Remoção de Caracteres Especiais:** Remove caracteres não alfanuméricos ou específicos da string

# Manipulação de Strings

## Problemas Encontrados



- Nomes com diferentes padrões.

|   |                 |                                                          |                             |                       |             |
|---|-----------------|----------------------------------------------------------|-----------------------------|-----------------------|-------------|
| 3 | CHRISTINE POPE  | 4097 Christopher FordSpearsborough, OH 25889             | valenzueladavid@example.net | 001-673-588-0900x676  | Individual  |
| 4 | Peter Rivas     | 650 Troy Viaduct Suite 923Wellsstad, NY 09689            | wheelerjames@example.net    | 001-889-724-0847x5707 | Corporativo |
| 5 | Keith Smith     | 21100 Spencer HarborSouth Monicaburgh, HI 73258          | riveraphillip@example.org   | 289-669-4176x4501     | Individual  |
| 6 | Joshua Phillips | 9412 Williams DriveEast Jamesshire, WA 70476             | katherine19@example.org     | 583.587.2790          | Individual  |
| 7 | matthew ellis   | 793 Rodriguez Wall Suite 005Melissaland, MN 02029        | brownjon@example.net        | 960.910.1967          | Individual  |
| 8 | sarah rogers    | 94517 Christopher Square Suite 079North Cassie, DE 12933 | amysmith@example.net        | 216.883.3497          | Individual  |

- Endereços com vírgulas, pontos e outros caracteres especiais que dificultam a análise.

| ClienteID | Nome            | Endereço                                                    | Email                   | Telefone           | Categoria   |
|-----------|-----------------|-------------------------------------------------------------|-------------------------|--------------------|-------------|
| 1         | Thomas Lee      | 408 Patricia Locks<br>Teresashire, CA 41158                 | sharonsmith@example.net | 308-380-8542       | Corporativo |
| 2         | Jeremiah Monroe | 18187 Cantrell Villages Suite 333<br>West Vincent. ID 53797 | kspence@example.com     | 922.991.9069x39453 | Corporativo |

- Emails com espaços em branco no início ou no fim que causam erros de validação.

| ClienteID | Nome       | Endereço                                    | Email                   | Telefone     | Categoria   |
|-----------|------------|---------------------------------------------|-------------------------|--------------|-------------|
| 1         | Thomas Lee | 408 Patricia Locks<br>Teresashire, CA 41158 | sharonsmith@example.net | 308-380-8542 | Corporativo |



**Preditiva.ai**





Preditiva.ai

# Fundamentos de ETL para Análise de Dados Combinando Dados de Diferentes fontes

# Join

## O que é?




Joins são operações que permitem **combinar registros de duas ou mais tabelas** com base em uma coluna comum, permitindo assim, integrar dados de diferentes fontes para análises mais completas.

Left Table

| Date     | CountryID | Units |
|----------|-----------|-------|
| 1/1/2024 | 1         | 40    |
| 1/2/2024 | 1         | 25    |
| 1/3/2024 | 3         | 30    |
| 1/4/2024 | 2         | 35    |

Right Table

| ID | Country |
|----|---------|
| 1  | USA     |
| 2  | Canada  |
| 3  | Panama  |
| 4  | Spain   |



Merged Table

| Date     | CountryID | Units | Country |
|----------|-----------|-------|---------|
| 1/1/2024 | 1         | 40    | USA     |
| 1/2/2024 | 1         | 25    | USA     |
| 1/4/2024 | 2         | 35    | Canada  |
| 1/3/2024 | 3         | 30    | Panama  |
| null     | null      | null  | Spain   |

## Por que usar Joins?

- Para integrar e consolidar dados de diferentes fontes.
- Para enriquecer análises com informações adicionais.
- Para identificar relações e padrões ocultos entre diferentes conjuntos de dados.

# Join

## Tipos de Joins



Existem vários tipos de joins que podem ser usados para combinar dados de diferentes tabelas, cada um com suas características e aplicações específicas. Os principais tipos de joins são: [Inner Join](#), [Left Join](#), [Right Join](#), e [Outer Join](#).

### Tipos de Join



- **Inner Join:** Combina registros que têm valores correspondentes em ambas as tabelas.
- **Left Join:** Retorna todos os registros da tabela à esquerda e os registros correspondentes da tabela à direita.
- **Right Join:** Retorna todos os registros da tabela à direita e os registros correspondentes da tabela à esquerda.
- **Full Outer Join:** Retorna todos os registros quando há uma correspondência em uma das tabelas.



**Preditiva.ai**




Preditiva.ai

# Fundamentos de ETL para Análise de Dados Carga Full e Incremental

# Carga Full

## O que é?

A carga full envolve a transferência completa de dados de uma origem para um destino. Todos os registros são carregados toda vez que o processo de ETL é executado.



## Vantagens

- **Simplicidade:** Fácil de implementar e gerenciar.
- **Consistência:** Garante que todos os dados estejam atualizados.


## Desvantagens

- **Tempo e Recursos:** Pode ser muito demorada e consumir muitos recursos, especialmente com grandes volumes de dados.
- **Desempenho:** Pode impactar negativamente o desempenho do sistema.

# Carga Incremental

## O que é?

A carga incremental envolve a transferência apenas dos dados que foram modificados ou adicionados desde a última carga. Apenas novos registros ou registros atualizados são carregados.



### Vantagens

- **Eficiência:** Menos tempo e recursos necessários em comparação com a carga full.
- **Desempenho:** Menos impacto no desempenho do sistema.

### Desvantagens

- **Complexidade:** Mais difícil de implementar e gerenciar.
- **Risco de Inconsistência:** Pode haver problemas de sincronização se não for bem gerenciado.

# Carga Full e Incremental

## Casos de Uso



### Carga Full

Volumes de dados pequenos

Em processos de inicialização.  
(primeiro retrato dos dados)

Quando há necessidade de uma  
atualização completa e imediata dos  
dados.

### Carga Incremental

Volumes de dados grandes

Em sistemas onde a atualização  
constante e rápida dos dados é  
crucial.

Em processos que precisam  
minimizar o uso de recursos.





**Preditiva.ai**



Preditiva.ai

# Fundamentos de ETL para Análise de Dados **ETL Além do Power Query**

# ETL Além do Power Query

## Limitações



- **Escalabilidade:** Dificuldade em lidar com grandes volumes de dados.
- **Automação:** Limitações na automação de processos de ETL.
- **Integração:** Desafios na integração com diversas fontes de dados complexas.
- **Recursos Avançados:** Falta de suporte para funcionalidades avançadas, como controle de versão e testes de qualidade.
- **Transformações Complexas de Dados:** Embora poderoso, o Power Query pode ser limitado em termos de flexibilidade e desempenho para transformações muito complexas.
- **Processamento em Tempo Real:** Não possui suporte e funcionalidades para casos de processamento em tempo real.

# ETL Além do Power Query

## As ferramentas



Existem diversas ferramentas que podem complementar ou substituir o Power Query para processos ETL mais complexos.





**Preditiva.ai**