



Preditiva.ai

Projeções e Análise Preditiva

O que são distribuições?

Probabilidades

Distribuições

Vimos que podemos utilizar as **frequências** calculadas de um evento para estimar as **probabilidades**.

Nesse contexto, quando temos **variáveis quantitativas (numéricas)**, uma forma de facilitar a obtenção de probabilidades é através do conceito de **distribuição** de probabilidades.

A **Distribuição de probabilidades** é a técnica para atribuir probabilidades aos possíveis valores de uma variável quantitativa.


Probabilidades

Distribuições - Exemplo

Uma forma de visualizar a distribuição de uma variável quantitativa é através de um **histograma**.

Por exemplo, temos um histograma com a **distribuição** do preço de **6.676 imóveis** em determinada região.


Baseado nesses dados, como poderíamos calcular a **probabilidade** de encontrar um imóvel com valor **abaixo de 180.000**?



Probabilidades

Distribuições - Exemplo

Podemos simplesmente realizar a **contagem** de preços até 180k para atribuir a **probabilidade** de se encontrar um imóvel até esse valor, caso busquemos um imóvel **aleatoriamente**. Veja:



Quando o histograma de determinada variável tem um formato mais “conhecido”, esse cálculo é ainda mais fácil, direto e **flexível**.



Preditiva.ai

Projeções e Análise Preditiva

Distribuição Uniforme

A premissa de igualdade

Probabilidades


Distribuição Uniforme – A premissa de igualdade

Quando os possíveis resultados de um **fenômeno aleatório** possuem a **mesma probabilidade de ocorrência**, dizemos que esse fenômeno tem **Distribuição Uniforme**.

Por essa característica, é **comumente** utilizada como **referência (baseline)** em cenários de incerteza onde há **poucas informações disponíveis**.

Também podemos utilizá-la para garantir **aleatoriedade**, seja em um cenário de **amostragem**, que é muito importante para algumas técnicas de Simulação, ou para **validar** se, de fato, há aleatoriedade em determinado processo.

Podemos calcular a probabilidade de um evento “uniforme” de forma simples: **1 / número de resultados possíveis**



Probabilidades

Distribuição Uniforme – A premissa de igualdade



Preditiva.ai


Demonstração

Probabilidades

Distribuição Uniforme – Demonstração



Audidores foram chamados para auferir as 60 esferas que fazem parte do sorteio da Mega Sena. Assim, desenvolveram um dispositivo que realizou 60 mil sorteios. O resultado está representado abaixo:



Com base nesse gráfico de frequência absoluta, você acha que a **probabilidade** de alguma das dezenas ser sorteada é **maior** do que de outras?

Probabilidades

Distribuição Uniforme – A premissa de igualdade



Preditiva.ai

Demonstração



Preditiva.ai

Projeções e Análise Preditiva


Distribuição Normal

A distribuição mais importante

Probabilidades

Distribuição Normal – A distribuição mais importante

A distribuição **Normal** é a **principal distribuição** de probabilidades da Estatística. Isso pelas suas propriedades e pela **relevância** em **diferentes** áreas do conhecimento.




Principais características da distribuição **Normal**:

1. Distribuição **simétrica**
2. **Concentração** de valores na posição central (média)
3. Frequência/Probabilidade tende a **zero** para valores muito baixos ou valores muito altos (em relação à média)
4. **Formato de “sino”**

Podemos calcular **probabilidades** em uma distribuição **normal** utilizando apenas sua **média** (valor esperado) e o **desvio padrão**.

Probabilidades

Distribuição Normal – A distribuição mais importante




Principais aplicações da distribuição Normal:

- Processos de **controle de qualidade**;
- **Modelagem de retorno** sobre ativos financeiros;
- Diversas variáveis em **ciências sociais**;
- **Premissa** para diversos **testes estatísticos** e modelos de previsão / **machine learning**;
- Entre outras aplicações.

Probabilidades

Distribuição T-Student – Distribuição derivada da Normal

A distribuição **T-Student** é uma **distribuição** de probabilidades derivada da **Distribuição Normal**, por isso herda algumas de suas características como **formato de sino** e **simetria** em relação à média



Principais aplicações da distribuição **T-Student**:

- **Técnicas de Inferência**
 - **Testes A/B**
 - **Intervalos de Confiança**
 - **Outras técnicas de estimação / testes estatísticos**
- **Aproximações em relação a Normal**
- **Entre outras**

Podemos calcular **probabilidades** em uma distribuição **T-Student** utilizando apenas
a quantidade de observações (graus de liberdade)

Probabilidades

Distribuição Normal – A distribuição mais importante




Demonstração

Probabilidades

Distribuição Normal – Demonstração

Uma fábrica que produz peças de plástico, precisa calcular a **probabilidade de uma peça fabricada ser defeituosa**. As peças com comprimento inferior a **1,24cm** ou superior a **2,11cm** são consideradas defeituosas pois estão fora da especificação e não poderão ser aproveitadas.



Considerando os dados de 2.000 peças coletados e apresentados no histograma ao lado:

- (I) Avaliar a **adequação** desses dados à uma distribuição **normal**
- (II) Calcular a **probabilidade** de termos uma peça **defeituosa**



Preditiva.ai

Projeções e Análise Preditiva

Outras Distribuições

Probabilidades

Outras Distribuições

Existem diversas outras **distribuições de probabilidades** utilizadas para calcular a probabilidade dos eventos de interesse em inúmeras situações. Neste quadro resumo mostramos as principais:

Tipo Variável	Distribuição	Principais aplicações práticas	Link
Discreta	Uniforme	Sorteios de números aleatórios.	https://pt.wikipedia.org/wiki/Distribuição_uniforme
Discreta	Bernoulli e Binomial	Taxa de sucesso em qualquer tipo de processo. Ex.: Vendas, Medicina, Controle de Qualidade etc.	https://pt.wikipedia.org/wiki/Distribuição_binomial
Discreta	Poisson	Contagens diversas: Marketing, Chamadas em um Call Center, veículos em um Pedágio etc.	https://pt.wikipedia.org/wiki/Distribuição_de_Poisson
Discreta	Geométrico	Estudo de cinemática da Física de objetos.	https://pt.wikipedia.org/wiki/Distribuição_geométrica
Discreta	Hipergeométrico	Cálculo da aceitação de lotes em fábricas.	https://pt.wikipedia.org/wiki/Distribuição_hipergeométrica
Contínua	Normal	Pesquisa, Ciências Sociais, Física, Medicina, Agricultura, Engenharia, Finanças etc.	https://pt.wikipedia.org/wiki/Distribuição_normal
Contínua	Gama	Contagens em um processo. Ex.: Necessidade dos consumidores.	https://pt.wikipedia.org/wiki/Distribuição_gama
Contínua	Qui Quadrado	Teoria de Qualidade do Ajuste	https://pt.wikipedia.org/wiki/Qui-quadrado
Contínua	Exponencial	Tempo até ocorrer um próximo evento	https://pt.wikipedia.org/wiki/Distribuição_exponencial
Contínua	t-Student	Estimação de média populacional com amostra pequena (menor que 30) e variância desconhecida.	https://pt.wikipedia.org/wiki/Distribuição_t_de_Student
Contínua	F de Fisher	Análise da Variância entre grupos	https://pt.wikipedia.org/wiki/Distribuição_F_de_Fisher-Snedecor



Preditiva.ai

Projeções e Análise Preditiva

Valor Esperado

Probabilidades

Valor Esperado

Vimos que uma variável quantitativa pode assumir **diversos valores** e a distribuição visualizada pelo Histograma ou com o uso das fórmulas (ex: Uniforme, Normal, etc) é a forma de obtermos as **probabilidades** de ocorrência desses valores.

Um conceito importante ao lidar com **distribuições** é o **Valor Esperado**, que é uma forma de **resumir** os valores da distribuição.

O **Valor Esperado** é o número que obtemos ao **ponderarmos** os possíveis **valores** de uma variável por suas **probabilidades de ocorrência**.

Em cenários de **incerteza**, é uma técnica importante para auxiliar a **tomada de decisão**.

Probabilidades

Valor Esperado - Exemplo

Considere um time de CRM de um e-commerce, atuando com a seguinte **estratégia de ativação** para o seu produto:

Novos clientes **recebem** um voucher de **R\$50** para gastar no site

Considere que esse novo cliente tem **15%** de probabilidade de ter **recorrência** na compra, com um **gasto esperado do cliente no site** de **R\$450**.

Do ponto de vista de retorno dessa estratégia, qual seria o **valor esperado**? Essa é uma estratégia **sustentável**?

Probabilidades

Valor Esperado - Exemplo

Utilizaremos o **valor esperado** para responder essa pergunta:

O **Valor Esperado** é o número que obtemos ao **ponderarmos** os possíveis valores de uma variável por suas **probabilidades de ocorrência**.

	Probabilidade de recorrência na compra	Gasto esperado quando tem recorrência na compra	Probabilidade de não ter recorrência na compra	Gasto com o voucher para esses clientes que não vão comprar novamente
Valor Esperado	15%	R\$450	85%	R\$50
=	*	+	*	=


Assim, nesse cenário é uma estratégia **sustentável**, pois o valor (retorno) esperado é **positivo**

Em distribuições mais “**conhecidas**”, temos fórmulas **mais “prontas”** para fazer esse cálculo

Probabilidades

Valor Esperado – Exemplo 2

Em um negócio de assinaturas, deseja-se entender o **LTV - Life time Value** (Valor trazido pelo cliente no tempo). Para isso, vamos entender o comportamento do cliente desse produto.



10 clientes fizeram a assinatura e pagaram a primeira mensalidade

6 clientes continuaram pagando no segundo mês

3 clientes continuaram pagando no terceiro mês

2 clientes continuaram pagando no quarto mês

Supondo que a assinatura custe R\$ 50 reais, qual o LTV médio de um cliente em 4 meses?

Probabilidades

Valor Esperado – Exemplo 2

Faz a assinatura	Paga a segunda mensalidade	Paga a terceira mensalidade	Paga a quarta mensalidade
Faz a assinatura			
Faz a assinatura	Paga a segunda mensalidade	Paga a terceira mensalidade	Paga a quarta mensalidade
Faz a assinatura			
Faz a assinatura	Paga a segunda mensalidade		
Faz a assinatura	Paga a segunda mensalidade		
Faz a assinatura	Paga a segunda mensalidade	Paga a terceira mensalidade	
Faz a assinatura	Paga a segunda mensalidade		
Faz a assinatura			
Faz a assinatura			

10 clientes fizeram a assinatura e pagaram a primeira mensalidade

6 clientes continuaram pagando no segundo mês

3 clientes continuaram pagando no terceiro mês

2 clientes continuaram pagando no quarto mês

Receita = 10 * R\$ 50 = R\$
500

6 * R\$ 50 = R\$
300

3 * R\$ 50 = R\$
150

2 * R\$ 50 = R\$
100

Portanto, o LTV médio em 4 meses seria:

$$\frac{500 + 300 + 150 + 100}{10} = 105 \text{ reais}$$

Probabilidades

Valor Esperado – Exemplo 2

Podemos chegar ao mesmo resultado usando o conceito de **valor esperado**. Para isso, precisamos saber a probabilidade do cliente estar ativo no mês e multiplicar pelo valor da assinatura. Veja:

	Quantidade de Clientes ativos no mês	Probabilidade de estar ativo no mês	Receita esperada
Mês 1	10	100%	R\$ 50
Mês 2	6	60%	R\$ 30
Mês 3	3	30%	R\$ 15
Mês 4	2	20%	R\$ 10

= 100% * R\$ 50 reais
= 60% * R\$ 50 reais
= 30% * R\$ 50 reais
= 20% * R\$ 50 reais

Soma de receita **R\$ 105**
(valor esperado)

Na prática na maior parte dos casos de negócio, é **mais fácil** usar o conceito de valor esperado para calcular as projeções, pois basta saber as probabilidade (usando frequências) e multiplicar pelo custo/valor.



Preditiva.ai


Projeções e Análise Preditiva

A lei dos grandes números

sugestão de motivação



Terminando a aula, você vai pedir aquele lanche. Que decisão você toma?



Opção 1: Nota 5, com 9 avaliações



Opção 2: Nota 4.9, com 649 avaliações



sugestão de motivação

Opção 2: Nota 4.9, com 649 avaliações



Por que a opção 2 é mais segura?

Pois segundo a **Teoria Frequentista**, quanto maior o tamanho da amostra, mais precisa é a probabilidade.

Outra técnica muito comum (e até mais adequada para o exemplo ao lado) é a **Lei dos Grandes Números**.

Essa lei significa que quanto maior o tamanho da amostra, mais a média desta amostra será próxima da média “real”.



Preditiva.ai

Projeções e Análise Preditiva

Análise Preditiva

Probabilidades

Análise Preditiva

O time de operações de um banco digital, preocupado com a disponibilidade dos serviços, solicitou ao time de **Analytics** um monitor que pudesse alertar o time períodos de volumetria abaixo do esperado no Pix.

A volumetria baixa pode ser um indício de algum problema ou indisponibilidade no serviço, e o alerta ajudaria na tempestividade da identificação.

Um dos analistas do time sugeriu utilizar os **dados históricos** para determinar um valor de “corte”, de forma que qualquer **valor futuro**, considerado “suspeito” por ser **muito baixo** ($< 1\%$ de probabilidade) , dispare o alerta.

Probabilidades


Análise Preditiva

A ideia é avaliar o padrão de **transações por hora**.

Por exemplo, à direita temos o **histórico dos últimos 2 anos** do volume de **transações** no intervalo entre 12h00 e 13h00

Utilizaremos o conceito de distribuições para determinar o valor de “corte” do alerta, para analisar os **períodos futuros** (12h-13h) .

Distribuição de Qtd de transações no intervalo 12h-13h nos últimos 2 anos



Demonstração



Preditiva.ai

Projeções e Análise Preditiva

Como avaliar nossa projeção?

Probabilidades

Análise Preditiva – Como avaliar nossa projeção?


Um dos analistas do time sugeriu utilizar os **dados históricos** para determinar um valor de “corte”, de forma que qualquer **valor futuro**, considerado “suspeito” por ser **muito baixo** ($< 1\%$ de probabilidade), dispare o alerta

A ideia é avaliar o padrão de **transações por hora**

Por exemplo, à direita temos o **histórico dos últimos 2 anos** do volume de **transações** no intervalo entre 12h00 e 13h00

Utilizaremos o conceito de distribuições para determinar o valor de “corte” do alerta, para analisar os **períodos futuros** (12h-13h)

Distribuição de Qtd de transações no intervalo 12h-13h nos últimos 2 anos





Como avaliar nossa projeção?


Probabilidades

Análise Preditiva – Como avaliar nossa projeção?

Depois de construir nosso “modelo” simplificado baseado na distribuição dos **dados históricos (últimos 2 anos)**, temos acesso aos dados dos **3 meses subsequentes**, com o alerta implantado

A principal premissa que utilizamos nessa projeção é a que **o futuro se comportaria “próximo” ao passado**, ou seja, que a distribuição observada se manteria.

Vamos **avaliar** nossa projeção e o índice de alertas gerados



?

Probabilidades


Análise Preditiva – Como avaliar nossa projeção?



Demonstração

Probabilidades

Será que sempre conseguimos prever o futuro?



O livro "**Cisne Negro**" (título original: "The Black Swan") é uma obra escrita por Nassim Nicholas Taleb, um filósofo, matemático e autor. Argumentos do livro:

- 1. Cisne Negro:** O termo "cisne negro" refere-se a eventos raros, imprevisíveis e de alto impacto que têm uma tendência significativa em moldar o curso da história e afetar nossas vidas.
- 1. Limitações das técnicas estatísticas:** O autor critica a dependência excessiva de técnicas estatísticas tradicionais, que assumem uma premissa de que o passado é o melhor preditor do futuro e falham em lidar com os cisnes negros.



Atentados



Crise de 2008



Caso Americanas

Probabilidades

Análise Preditiva - Reflexões



É possível ao menos **melhorar as previsões** ou diminuir os impactos de erros de previsão?

Geralmente **sim**. Algumas técnicas usadas para melhorar as previsões:

- ☐ Ter acesso a mais dados. Quanto mais dados (tanto em volume quanto em variedade), melhor
- ☐ Uso de modelos de probabilidade (Ex: Normal, Regressão Logística etc)
- ☐ Uso de modelos de Machine Learning (quando temos muitos dados e com boa variedade) e boas práticas de acompanhamento de sua performance
- ☐ Ter uma boa gestão de risco (como lidar com cisnes negros)?