



Preditiva.ai

Foundations


Noções de Inferência Estatística

Noções de Inferência Estatística

O que é?

A **Inferência** é o conjunto de técnicas que possibilitam a “extensão”, a um grande conjunto de dados, das informações e conclusões obtidas a partir de uma pequena quantidade de dados, ou seja, de uma **amostra**.

Assim, podemos dizer, que é a técnica a ser utilizada quando não temos acesso aos dados completos, ou seja, quando não temos acesso à **população** de interesse.



Noções de Inferência Estatística

O que é?



Em quais situações não temos acesso à população de interesse? Vejamos alguns exemplos:

1. Problemas econômicos:

- É muito custoso entrevistar todas as pessoas de interesse. Ex.: Habitantes do Brasil.
- Nem todas as pessoas estão acessíveis. Ex.: Clientes de um restaurante às 19h.

2. Problemas físicos:

- Imagine o problema de se testar a durabilidade das lâmpadas. O teste poderia queimar todas elas.

3. Problemas éticos:

- Testes de remédios em seres vivos pode causar grandes efeitos colaterais. Testar em toda a população seria prudente?

Noções de Inferência Estatística

Conceitos Fundamentais




Agora que sabemos que extrair uma amostra é uma alternativa interessante para o problema de acesso à população, podemos nos perguntar: **Qualquer amostra representa bem uma população?**

Vejamos em um exemplo:

Suponha que queremos **estudar a renda per capita do Brasil**. Para isso, entrevistamos as pessoas de São Paulo e perguntamos sua renda anual.

Pergunta:

Essa amostra representa bem a população ?



Noções de Inferência Estatística

Conceitos Fundamentais




O problema dessa abordagem é que a renda per capita **não** é **homogênea** no país. Considerar apenas um estado brasileiro causa um **viés de seleção**.

Para tentar resolver, o pesquisador ligou para cada um de seus amigos que **moram em cada estado do país**. Com isso, perguntou a renda anual de seus conhecidos.

Pergunta:

Essa amostra representa bem a população ?



Noções de Inferência Estatística

Conceitos Fundamentais



O problema dessa outra abordagem é que, ao entrevistar apenas seus amigos, o pesquisador selecionou uma **amostra por conveniência**. Com isso ele pode ter causado um outro **viés de seleção**.

Uma abordagem mais satisfatória seria sortear aleatoriamente um conjunto de pessoas do Brasil, independente do estado. Essa técnica de amostragem é chamada **Amostragem Aleatória Simples (AAS)**.

A **Amostragem Aleatória Simples (AAS)** tem como principal benefício a garantia de obter amostras que tenham **a mesma probabilidade de ocorrência**. Com isso, é mais seguro extrapolar suas conclusões para a população de interesse. Temos basicamente dois tipos de AAS. São eles:

1. **AAS sem reposição:** Quando temos que remover a unidade sorteada para não correr o risco de ser sorteada novamente na próxima coleta. Ex: Bolas em uma urna. Ao sortear uma bola, devemos removê-la da urna.
2. **AAS com reposição:** Quando não removemos a unidade sorteada. Ex: Ao sortear uma bola, devemos devolvê-la para a urna, de modo a garantir a possibilidade que ela seja sorteada novamente.

Noções de Inferência Estatística

Conceitos Fundamentais



Voltando para o estudo da **renda per capita do Brasil**, quais **outros problemas poderiam prejudicar** a qualidade da **amostra** do estudo?

Tamanho da amostra

Segundo o IBGE*, o Brasil tem mais de **208 milhões de habitantes com diversas características**. Com isso, é de se esperar que a amostra tenha um tamanho adequado.

Por mais que tenhamos o cuidado de ser aleatória, **não é razoável** entrevistar apenas um ou dois habitantes de cada estado brasileiro.

Sabendo disso, **qual o tamanho de amostra adequado?** Iremos estudar esse assunto mais adiante no curso.

Erro de leitura/coleta

Muito comum de acontecer, os erros de coleta são difíceis de resolver. Se o entrevistador anotar valores errados durante a entrevista ou ainda não ter cuidado com a forma de realizar a pergunta, pode **aumentar muito a imprecisão do estudo**. Vejamos um exemplo:

Um entrevistador pergunta o que o cliente acha de uma operadora de celular. Para isso, realiza a seguinte pergunta: **Por que você acha que a operadora X é melhor que a operadora Y ?**

Noções de Inferência Estatística


Conceitos Fundamentais



Agora que vimos os principais cuidados a serem tomados na escolha de uma boa amostra, **o que vem a seguir para continuar o processo de Inferência?** A escolha de um bom **estimador**. Vejamos algumas definições:

A população de interesse guarda o **parâmetro de interesse**, geralmente denotado por letras gregas θ, μ, σ etc.

No estudo anterior, a **população** dos habitantes do Brasil têm o **parâmetro de interesse** “Renda Per Capita”.



Usando os valores da amostra, escolhemos um **estimador** para o parâmetro de interesse. Este estimador geralmente é denotado por letras gregas com “chapéu”. Ex: $\hat{\theta}, \hat{\mu}, \hat{\sigma}$.

Através do estimador, calculamos uma **estimativa** para o parâmetro de interesse.

Noções de Inferência Estatística

Conceitos Fundamentais



São muitos os estimadores de algum parâmetro populacional. A questão que devemos responder é: **Qual o melhor estimador que podemos escolher?** Essa escolha depende de 3 conceitos fundamentais:

Viés

O viés de um estimador é a diferença entre sua média e o parâmetro de interesse. Ou seja, um estimador é dito **não-viesado** quando sua média coincide com seu parâmetro populacional.

Variância

O estimador que deve ser escolhido é aquele que tem a menor variância possível. Quando um estimador tem variância mínima, dizemos que ele é **preciso**.

Consistência

Além do estimador ser não-viesado e de variância mínima, queremos que o estimador seja consistente. Um estimador é dito **consistente**, quando:


$$\lim_{n \rightarrow \infty} Média(\hat{\theta}) = Parâmetro \quad e \quad \lim_{n \rightarrow \infty} Variância(\hat{\theta}) = 0$$

Ou seja, a medida que o tamanho da amostra aumenta, o estimador perde o viés e sua variância fica próxima de 0 (zero).

Noções de Inferência Estatística

Conceitos Fundamentais

Vejam os seguintes exemplos dos tipos de estimadores. **Qual o melhor estimador?**



Quadro **resumo dos estimadores** para os principais parâmetros de interesse:

Parâmetro de interesse	Estimador	Propriedades
μ (Média populacional)	$\bar{X} = \frac{x_1 + x_2 + \cdots + x_n}{n}$	Não-viesado e consistente
p (Proporção populacional)	$\hat{p} = \frac{\text{frequência amostral}}{n}$	Não-viesado e consistente
σ^2 (Variância populacional)	$S^2 = \frac{1}{n - 1} \sum_{i=1}^n (x_i - \bar{X})^2$	Não-viesado e consistente

Portanto, para um bom processo de Inferência Estatística, **precisamos tomar os seguintes cuidados:**

- ❑ Escolher uma amostra que seja **uma boa representante da população** de interesse.
Para isso, devemos:
 - Sortear a amostra aleatoriamente ou com o menor viés de seleção possível
 - Calcular um tamanho de amostra adequado
 - Tomar cuidado com erros de escrita/leitura dos dados
 - Mensurar os dados sem influenciar as respostas (Ex: perguntas tendenciosas)

- ❑ Escolher **um bom estimador para o parâmetro** de interesse





Como vimos nesta aula, **são muitos os fatores que levam a erros metodológicos** no processo de Inferência Estatística.

Quem nunca se perguntou **como os institutos de pesquisa erram** ao tentar estimar parâmetros de interesse como as intenções de votos em um país.

Sem dúvida alguma, boa parte dos problemas devem-se aos erros explicados nesta aula.

Desta forma, lembre-se sempre: **Ao ouvir falar sobre algum estudo que usa o processo de Inferência Estatística, sempre verifique as premissas utilizadas no estudo. Só assim você pode confiar (ou não) nos resultados apresentados.**



Revisão

Nesta aula aprendemos que **Inferência Estatística** é a área da **Estatística** responsável pelas técnicas que nos permitem extrapolar os resultados de uma amostra para toda a população.

Vimos também que devemos tomar diversos cuidados na **seleção de uma amostra da população**, pois **vieses de seleção, tamanho inadequado, parcialidade** na realização de perguntas e **erros de leitura / escrita** dos dados gerarão **resultados distorcidos**.

E por último, que além de tomar todos esses cuidados com a amostra, devemos também utilizar **estimadores com boas propriedades de viés, variância e consistência**.





Preditiva.ai

Noções de Inferência Estatística


Teorema do Limite Central

Noções de Inferência Estatística

Teorema do Limite Central



- Suponha que exista uma **maratona na cidade**.
- Vários **ônibus** estão transportando os maratonistas para o evento.
- Antes do início da maratona, algo inusitado aconteceu: **Um dos ônibus não chegou ao destino...**




Noções de Inferência Estatística

Teorema do Limite Central



Preditiva.ai

- A polícia foi acionada para buscar os desaparecidos.
- Após algumas horas de busca, **um ônibus apareceu na estrada.**
- Você pede para que os passageiros saiam do ônibus para serem identificados. Eis os passageiros:



Noções de Inferência Estatística

Teorema do Limite Central



Rapidamente você **estima que a idade média** dos passageiros do ônibus é de **8 anos**.

Com base nessa estimativa, pergunta-se:

Esse é o ônibus perdido que você estava procurando?

Se você acha que é **muito pouco provável que um ônibus (a amostra)** de passageiros tão jovens sejam maratonistas, parabéns! Você entendeu a ideia principal do **Teorema do Limite Central (TLC)**.

O princípio essencial do TLC é que uma amostra grande, adequadamente escolhida, será muito próxima da população que foi retirada.


Noções de Inferência Estatística

Teorema do Limite Central




Verificação do **Teorema do Limite Central** utilizando simulações:


População com Distribuição Uniforme (0,1)




População com Distribuição Uniforme (0,1)
Média com $n = 2$




População com Distribuição Uniforme (0,1)
Média com $n = 10$




População com Distribuição Uniforme (0,1)
Média com $n = 100$




População com Distribuição Gama (1,1)




População com Distribuição Gama (1,1)
Média com $n = 2$



População com Distribuição Gama (1,1)
Média com $n = 10$



População com Distribuição Gama (1,1)
Média com $n = 100$



Noções de Inferência Estatística

Teorema do Limite Central



Além disso, o TLC nos diz que:

1. Se você obter amostras grandes, aleatórias, de qualquer população, as médias dessas amostras serão distribuídas normalmente em torno da média da população.
2. A maioria das médias de amostras estará razoavelmente perto da média da população. O desvio padrão é o que define “razoavelmente perto”.
3. Quanto menos provável for um resultado observado, mais confiantes podemos estar em presumir que a população de origem é bem diferente da amostra que estamos analisando.

Noções de Inferência Estatística

Teorema do Limite Central



O **Teorema do Limite Central** é muito importante porque ao caracterizar a distribuição de probabilidades da **média amostral**, podemos:

- Calcular uma estimativa da **média populacional**
- Calcular o desvio padrão da estimativa da **média populacional**
- Calcular percentis para avaliar a estimativa da **média populacional**

Revisão

Nesta seção aprendemos:

- O que é o **Teorema do Limite Central** e qual sua importância.
- Como utilizar o resultado do **Teorema do Limite Central** para caracterizar a distribuição da média amostral.
- Calcular alguns percentis para analisar a distribuição da média amostral.



Próximos passos

Na próxima seção aprenderemos como fazer **estimativas pontuais e por intervalo**, ou seja, além da estimativa, conheceremos uma forma de calcular a **incerteza** sobre essa própria estimativa.

Conhecer as **incertezas das estimativas é algo extremamente útil** no mundo de Analytics! Essa informação é fundamental na análise dos dados e deve sempre ser considerada na tomada de decisões.





Preditiva.ai

Inferência Estatística

Estimação Pontual e por Intervalo


- Média Populacional

Noções de Inferência Estatística

Estimação Pontual



Como vimos anteriormente, a **Inferência Estatística** busca **generalizar** informações sobre uma **População** a partir de dados de uma **Amostra**. Essa **generalização** é obtida através de **métodos de estimação dos parâmetros** de uma população.



Noções de Inferência Estatística

Estimação Pontual



Vamos iniciar esse tema com o seguinte exemplo:

Considere que um fabricante de automóveis deseja saber a **média de idade** dos seus clientes que compraram seu último modelo. Para isso, realizou uma pesquisa com **30 pessoas** em todo o Brasil e calculou a média de idade em **31** anos.

Considerando que a **amostra representa bem a população**, vimos que um estimador não-viesado e de baixa variância para a **média populacional** de idade é:

$$\text{Média amostral} = \hat{\mu} = 31$$

Algumas perguntas que podemos fazer são:

- Essa é uma boa estimativa?
- Qual é o tamanho **do erro** na estimação da idade média?

Noções de Inferência Estatística

Estimação por Intervalo



Para quantificarmos com maior precisão o **erro na estimação da média populacional**, utilizamos os **Intervalos de Confiança**. Vamos calculá-lo para a **média populacional μ** com **90% de confiança**.

$$IC (\mu; 90\%) = (\hat{\mu} - t_{n-1} \cdot \sqrt{\frac{s^2}{n}}; \hat{\mu} + t_{n-1} \cdot \sqrt{\frac{s^2}{n}})$$

$\hat{\mu}$: média amostral

s^2 : variância amostral

n : número de observações

t_{n-1} : valor da distribuição t-Student

Noções de Inferência Estatística

Estimação por Intervalo



Além dos dados informados anteriormente, o fabricante calculou também a **variância amostral** e obteve o valor de **25**. Dessa forma, temos todos os dados para o cálculo do **Intervalo de Confiança**:

$\hat{\mu}$: média amostral = 31


S^2 : variância amostral = 25

n : número de observações = 30

t_{n-1} : valor da distribuição t-Student = 1,70

 =INV.T(prob ; n-1)

$$IC(\mu; 90\%) = \underbrace{(31 - 1,70 \cdot \sqrt{\frac{25}{30}})}_{29,4}; \underbrace{(31 + 1,70 \cdot \sqrt{\frac{25}{30}})}_{32,6}$$



Noções de Inferência Estatística

Estimação por Intervalo



Podemos dizer então que o **Intervalo de Confiança** para a média populacional (idade dos clientes da empresa), com um **Nível de Confiança (γ) de 90%** é:

$$IC (\mu ; 90\%) = (29,4 ; 32,6)$$

Pergunta: Como devemos interpretar o **Intervalo de Confiança** acima?

- a) Existe 90% de probabilidade da média de idade na população estar em 29,4 e 32,6 ?
- b) A real média da população irá cair entre 29,4 e 32,6 em 90% das vezes.
- c) O intervalo de confiança de 29,4 e 32,6 pode ser um dos 90 intervalos calculados a cada 100 intervalos diferentes que pode conter a real média de idade da população.

Noções de Inferência Estatística

Estimação por Intervalo



Podemos dizer então que o **Intervalo de Confiança** para a média populacional (idade dos clientes da empresa), com um **Nível de Confiança (γ) de 90%** é:

$$IC (\mu ; 90\%) = (29,4 ; 32,6)$$

O **Intervalo de Confiança** deve ser interpretado como:


“Se realizássemos um **grande número de amostras aleatórias de tamanho n** e calculássemos o **Intervalo de Confiança** para todas elas, **90% desses intervalos conteriam a real média da população (parâmetro μ)** ”

Noções de Inferência Estatística

Estimação por Intervalo



Calculando 100 **Intervalos de Confiança** utilizando os parâmetros deste exemplo, temos o gráfico abaixo:




Noções de Inferência Estatística

Estimação por Intervalo



Supondo que a idade populacional seja 32. Perceba que as linhas destacadas em azul
essa idade não está contida no **Intervalo de Confiança**.




Noções de Inferência Estatística

Estimação por Intervalo



Podemos perceber que dos 100 **Intervalos de Confiança** calculados, 89 contém o parâmetro populacional (89%).



Noções de Inferência Estatística

Estimação por Intervalo




Se aumentarmos o **Nível de Confiança** para 95%, o **Intervalo de Confiança** será:

- $\text{INV.T}(0,025 ; 30-1) = -2,05$

- $\text{INV.T}(0,975 ; 30-1) = +2,05$



$$\text{IC}(\mu ; 95\%) = (29,1 ; 32,9)$$



Noções de Inferência Estatística

Estimação por Intervalo



Dessa forma, com **30 entrevistados**, o fabricante de automóveis calcula que com **90% de confiança**, a média de idade dos compradores de todos os veículos do último modelo está entre **29,4** e **32,6**:

$$IC (\mu ; 90\%) = (29,4 ; 32,6)$$

E com **95% de confiança**, a média de idade dos compradores está entre **29,1** e **32,9**:

$$IC (\mu ; 95\%) = (29,1 ; 32,9)$$


Noções de Inferência Estatística

Estimação por Intervalo



Preditiva.ai

Exemplo visual:



<https://seeing-theory.brown.edu/frequentist-inference/index.html#section3>



Preditiva.ai

Inferência Estatística

Estimação Pontual e por Intervalo

- Proporção Populacional

Noções de Inferência Estatística

Estimação por Intervalo



Em problemas relacionados com **percentual** ou **proporção populacional** (em vez da média como vimos nos exemplos), procedemos da mesma forma, exceto pelas seguintes mudanças:

$$IC(p; 90\%) = \left[\hat{p} - t_{n-1} \cdot \sqrt{\frac{\sigma_{\hat{p}}^2}{n}} ; \hat{p} + t_{n-1} \cdot \sqrt{\frac{\sigma_{\hat{p}}^2}{n}} \right]$$

Intervalo de confiança
para a proporção populacional

Sendo,

$$\hat{p} = \frac{\text{Frequência do evento de interesse}}{\text{número total de eventos}}$$

Proporção amostral

$$\sigma_{\hat{p}}^2 = \hat{p}(1 - \hat{p})$$

Variância da proporção
amostral



Preditiva.ai

Inferência Estatística Margem de Erro e Tamanho na Amostra

Vimos anteriormente que a **Estimação Pontual e por Intervalo** visa **extrapolar** os resultados obtidos de uma **amostra** para a **população**.

Aprendemos que por utilizar uma **amostra**, temos um **erro intrínseco ao cálculo dos estimadores**. E por esse motivo, é importante calcular além da estimação pontual, a estimação por intervalo, os chamados **Intervalos de Confiança**.

Vamos entender agora como podemos **controlar o erro nas estimações variando o tamanho da amostra**.

Para apresentar o conceito de **Margem de Erro**, vamos relembrar o exemplo da seção anterior.

Com **30 entrevistados**, o fabricante de automóveis calculou que a média de idade dos compradores de veículo foi de **31**, e com **90% de confiança**, o percentual populacional estaria entre **29,4 e 32,6**.

$$IC (\mu ; 90\%) = (29,4 ; 32,6)$$


Noções de Inferência Estatística

Margem de Erro



Nesse contexto, dizemos que a **Margem de Erro** na estimação do parâmetro μ com **Nível de Confiança de 90%** é de **1.6**, pois essa é a distância entre a **média amostral** e os **limites do Intervalo de Confiança**.

Distribuição da Média Amostral



Digamos que o fabricante de automóveis não tenha ficado muito satisfeito com a **Margem de Erro** dessa estimação. Como podemos fazer para reduzir essa incerteza na estimação da média de idade dos compradores do último modelo?

“Calculando um **Tamanho de Amostra** compatível com a **Margem de Erro** desejada pelo fabricante”

Noções de Inferência Estatística

Cálculo do Tamanho da Amostra



Para calcular o **Tamanho da Amostra** utilizamos a equação a seguir:

$$n = \frac{S^2 z_{\gamma}^2}{\varepsilon^2}$$

Onde:

- **n**: tamanho da amostra que teremos após o cálculo
- **S²**: variância amostral
- **z_γ**: quantil do Nível de Confiança usando a distribuição Normal
 - **Função no Excel**: `INV.NORMP.N( ( 1- NIVEL DE CONFIANCA ) / 2 )`
- **ε**: Margem de Erro desejada

Noções de Inferência Estatística

Cálculo do Tamanho da Amostra



O fabricante de automóveis deseja que a **Margem de Erro** na estimação da média de compradores seja **inferior a 1,0**.

Dessa forma, o **Tamanho da Amostra** mínimo necessário para obter uma **Margem de Erro** inferior a solicitada pelo fabricante é (supondo que a variância amostral da idade das 30 pessoas entrevistadas seja **25**):

$$n = \frac{S^2 z_{\gamma}^2}{\epsilon^2} = \frac{25 \cdot 1,65^2}{1^2} = 68$$

Ou seja, para obter uma **Margem de Erro inferior a 1** precisamos ter uma amostra com **pelo menos 68** pessoas entrevistadas.

Próximos passos

Nesta seção aprendemos como calcular a **Margem de Erro** e como calcular o **Tamanho da Amostra** de forma a controlar a **Margem de Erro**.

Nas próximas aulas veremos como usar a técnica **Testes de Hipóteses** para comparar grupos diferentes de dados. Muito importante em vários projetos de Dados no nosso dia a dia.

Até lá !





Preditiva.ai