



Preditiva.ai

Framework de Desenvolvimento de Modelos Metodologia Ágil em Data Science


Framework de Desenvolvimento de Modelos

Etapas de um projeto de Data Science



Preditiva.ai

Agora que passamos pelas principais técnicas de desenvolvimento de modelos, precisamos encapsular todo esse conhecimento em uma metodologia de desenvolvimento. Uma abordagem comum é a chamada **CRISP-DM**. Veja:



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Por muito tempo, o **CRISP-DM** foi o principal framework de desenvolvimento. No entanto, com o advento das **metodologias ágeis** para desenvolvimento de produtos, muito se fala em como agregar os benefícios dessas metodologias para projetos de Ciência de Dados.


Alguns dos motivadores dessa mudança:

- Como o próprio nome diz, **Ciência** de Dados é uma área baseada em experimentação. Diferentemente de Engenharia de Software, onde os resultados esperados são determinísticos, em **Ciência de Dados o resultado final em geral é imprevisível**. Portanto, um cuidado de aplicar o CRISP-DM é de torná-lo puramente linear (seguir os passos sem voltar passos anteriores ou fazer pausas para apresentação das descobertas).
- Se aplicado de forma linear, o cliente só terá insights e benefícios no final do projeto, que pode demorar muito. Por exemplo, em bancos tradicionais, em geral **um projeto de modelagem dura entre 5 a 10 meses**.

Abordagem Tradicional. Ex: CRISP-DM



Nova Abordagem: Metodologia Ágil para Data Science




Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science



Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

1

Principais entregáveis dessa task:

- Levantamento do escopo do projeto;
- Definição de **métricas de sucesso**. Ex: Melhoria de KS/ROC, maior quantidade de GH's/Scores de Crédito, Primeira versão de um modelo etc.
- Definição do **público alvo**. Ex: Clientes com mais de um mês de conta e com atividade no mês anterior.
- Construção do **Target** do Modelo. Ex: Clientes que deram Churn no mês posterior ao mês referência.
- **Extração de variáveis** iniciais. Ex: Variáveis cadastrais e de transações dos clientes.



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

2

Principais entregáveis dessa task:

- Análise **univariada** (ou seja, frequências relativas, visualização de dados, medidas resumo – média, mediana, desvio padrão, de cada variável da base)
- Análise **bivariada** (quais variáveis mais se relacionam como Target?)
- A cada descoberta (*insight*), deve-se marcar reuniões (denominadas “Syncs”) com os stakeholders para **compartilhar os resultados e pedir feedback**. É comum o escopo do projeto mudar de acordo com essas descobertas.
- Caso o escopo mude, atualizar as métricas de sucesso. Caso contrário, **atualizar o backlog** do projeto para uma possível versão 2.



Metodologia Ágil para Data Science

Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

3

Principais entregáveis dessa task:

- Em vez de ajustar/otimizar cada variável da base de forma a prepará-la para a modelagem, é muito **mais útil desenvolver/treinar um modelo inicial bem simples** para já obter insights do problema. Ex:
 - Qual o KS/ROC inicial? É suficiente?
 - O modelo tem overfitting ou underfitting?
 - É necessário obter mais observações/linhas?
 - É necessário obter mais variáveis/colunas?
 - Quais variáveis são mais importantes para o problema?
- Preparação dessas descobertas para uma próxima reunião de Sync com os stakeholders. Ajuste o projeto de acordo com as possíveis mudanças acordadas na reunião.



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

4

Principais entregáveis dessa task:

- Após o aprendizado do modelo inicial, pode-se tomar as seguintes ações:
 - Correção do overfitting ou underfitting;
 - Teste de modelos mais sofisticados. Ex: Ensemble de Modelos como o Random Forest ou Boosting.
 - Tuning de Hiperparâmetros. Ex: Critérios de Podas das árvores.



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

5

Principais entregáveis dessa task:

- Nesta etapa, criamos o chamado **MVM (Modelo Mínimo Viável)**. O conceito é análogo ao do MVP de produtos, em que desenvolvemos um produto funcional com poucas features, mas que já é possível colocar em produção para validar e colher feedback dos usuários.
- Na mesma linha do MVM, podemos ter o MVP (Plataforma Mínima Viável) ou MVD (Data Product Mínimo Viável).
- Um grande avanço das metodologias de desenvolvimento de modelos advém desse conceito, pois era muito comum ficar muitos meses estudando e otimizando um mesmo modelo antes de colocar em produção.



5

Desenvolvimento do MVM

Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

6

Principais entregáveis dessa task:

- Nesta etapa, outros cientistas de dados (geralmente os especialistas ou Tech Leads) são responsáveis por **verificar o processo de desenvolvimento** do modelo inicial. A ideia é ter uma camada de controle para mitigar riscos operacionais.
- Em empresas grandes, a área responsável por essa revisão é a **área de Validação de Modelos**, muito comum em bancos tradicionais. Essas áreas têm uma metodologia própria de validação, incluindo a relevância do modelo para a organização (Tier), riscos envolvidos do produto, inventário de modelos, documentação obrigatória entre outros.
- No contexto do ágil, essas áreas também devem evoluir nas suas abordagens, sob o risco de virarem **“gargalo” no processo**.



6

Peer Review

Desenvolvimento do MVM

Aprendizado e inclusão de novas features

Desenvolvimento de um Baseline

Análise Exploratória

Escopo e Extração das Variáveis

Nova sprint de melhorias

Acompanhamento e documentação

Deploy do modelo

Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

7

Principais entregáveis dessa task:

- Nesta etapa, o **código do modelo é enviado** para uma área de Engenharia de Dados ou Engenharia de Machine Learning realizar a implantação nos servidores da empresa. Ex: Ferramentas como SAS, SQL Server, Amazon Web Services (AWS), Docker, API's entre outros são utilizadas com frequência.
- Nas áreas de Crédito, também é muito comum a abordagem de **Motores de Crédito** proprietários que fazem a decisão de Crédito com o uso do modelo desenvolvido. Ex: FICO® Blaze.
- Outra questão importante é implantar o modelo para uma parte do público (Teste) e deixar o restante com o modelo anterior (Controle). Desta forma minimiza-se riscos operacionais devido à performance do **modelo desafiante (nova versão)**.



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science




Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

8

Principais entregáveis dessa task:

- Nesta etapa, após a implantação do modelo, deve-se acompanhá-lo frequentemente para identificar oportunidades de melhoria com o passar do tempo.
- No processo de acompanhamento, olhamos métricas de **Discriminação** (métricas KS e ROC), **Estabilidade** Populacional (métrica PSI) dos scores e **Previsibilidade** (o quanto cada score mantém seu patamar de performance) ao longo do tempo.
- Caso o modelo perca performance (o que é bem normal), podemos **retreinar** o modelo ou apenas fazer uma **calibração** (ajuste dos scores e/ou patamares de performance).
- **Documentação**: Fechar a documentação do modelo, incluindo o objetivo do modelo, stakeholders, versionamento, critérios do público alvo, target, filtros realizados, premissas consideradas, técnica de modelagem escolhida, análise exploratória, resultados finais, métricas de performance em treino e validação OOT, atualização do backlog, entre outros.



Framework de Desenvolvimento de Modelos

Metodologia Ágil para Data Science



Preditiva.ai

Ainda não temos uma metodologia definitiva que mescla os conceitos do CRISP-DM com os de Metodologias Ágeis como o **Scrum** ou **KanBan**. No entanto, a maioria dos frameworks seguem basicamente as etapas do ciclo ao lado:

9

Principais entregáveis dessa task:

- Nesta etapa, agora que o modelo está em produção e em acompanhamento, pode-se **revisitar o backlog de melhorias** que foi sendo preenchido no desenvolvimento do MVM e iniciar as novas versões do modelo. Pode-se:
 - ☐ Atualizar o público alvo e target;
 - ☐ Acrescentar novas variáveis explicativas;
 - ☐ Testar outras técnicas de Machine Learning;
- As abordagens ágeis em Data Science têm como principais forças:
 - ☐ Entrega de **valor constante para o cliente**;
 - ☐ Grande **melhoria do "Time to Market"**;
 - ☐ Novo mindset de **melhoria contínua**;

