



Preditiva.ai

Aprendizado Supervisionado

Regressão Linear

Introdução

Regressão Linear

Introdução



A **Regressão Linear** é um dos métodos mais famosos para se interpretar a relação de uma variável de seu interesse (**variável resposta ou *Target***) com outra variável (**variável explicativa ou *feature***).

Enquanto com a correlação linear de Pearson conseguimos quantificar o nível de associação entre as duas variáveis, com a regressão conseguimos inclusive “**modelar**” esse grau de associação construindo uma equação que explica a mudança da variável resposta em relação às mudanças da variável explicativa.

Vejamos um exemplo a seguir.

Regressão Linear

Uma variável explicativa



Preditiva.ai

Exemplo dos primeiros 15 funcionários

Uma empresa está interessada em verificar se a **remuneração** dos seus colaboradores está de acordo com as políticas vigentes. Para isso coletou uma amostra de **46 colaboradores** conforme a seguir.

A pergunta de negócio é:

O salário muda de acordo com os anos de educação superior? Se sim, é possível construir um modelo que estime o salário de acordo com esses anos?


Núm. Funcionário	Salário	Anos de Educação Superior
1	5.517,40	3
2	6.399,90	4
3	6.206,70	6
4	6.060,60	4
5	6.122,70	2
6	6.955,00	5
7	7.643,00	4
8	6.210,20	2
9	5.761,00	9
10	8.086,90	6
11	6.375,40	4
12	9.568,80	6
13	9.316,00	6
14	6.822,40	9
15	6.570,90	4

Regressão Linear

Uma variável explicativa



Em uma **análise bidimensional** de **duas variáveis quantitativas**, devemos **construir um gráfico de dispersão**. Vejamos a seguir.



O gráfico de dispersão nos informa que as duas variáveis são **correlacionadas positivamente**, pois aparentemente quanto mais anos de educação, maior é o salário nesta empresa. Pelo formato da “nuvem de pontos”, também é possível sugerir que uma reta pode ser traçada no meio da nuvem.


Portanto, as variáveis têm uma associação aproximadamente linear e podemos quantificar essa associação com o **coeficiente de correlação de Pearson** (Correlação = 0,78).

Regressão Linear

Uma variável explicativa



Em uma **análise bidimensional** de **duas variáveis quantitativas**, devemos **construir um gráfico de dispersão**. Vejamos a seguir.



Pelo comportamento observado, podemos propor uma **reta** que represente a **relação entre o salário e os anos de educação**, com a seguinte equação:

$$\text{Salario} = \overset{\text{(Intercepto)}}{\beta_0} + \underset{\substack{\text{(Coeficiente} \\ \text{Angular de} \\ \text{Anos de Educação)}}}{\beta_1} * \text{Anos de Educacao}$$

Resta agora saber quais são os valores de β_0 e β_1 que melhor se ajusta aos dados.

Vamos aprender como podemos encontrar esses valores utilizando a biblioteca **statsmodels** no Python.

Demonstração

Regressão Linear no Python

Arquivo **1_Regressao_Linear_Simples.zip** contém:

- 1_Regressao_Linear_Simples.ipynb
- base_funcionarios_v1.csv


Regressão Linear

Uma variável explicativa



Dessa forma, chegamos ao **modelo** que estima o salário a partir dos anos de educação:

$$\text{Salario} = 4.301,80 + 526,73 * \text{Anos de Educacao}$$



A partir deste modelo extraímos importantes interpretações:

1. O salário médio estimado de um funcionário com 0 anos de educação superior é de **R\$ 4.301,80**, representado pelo **intercepto da reta**.
2. O salário médio estimado de um funcionário aumenta em média **R\$ 526,73** para cada ano adicional de educação superior, representado pelo **coeficiente angular da reta**.



Preditiva.ai

Aprendizado Supervisionado

Regressão Linear

Múltiplas variáveis explicativas


Regressão Linear

Uma variável explicativa



Na aula passada chegamos ao **modelo** que estima o salário a partir dos anos de educação:

$$\text{Salario} = 4.301,80 + 526,73 * \text{Anos de Educacao}$$



A partir deste modelo extraímos importantes interpretações:

1. O salário médio estimado de um funcionário com 0 anos de educação superior é de **R\$ 4.301,80**, representado pelo **intercepto da reta**.
2. O salário médio estimado de um funcionário aumenta em média **R\$ 526,73** para cada ano adicional de educação superior, representado pelo **coeficiente angular da reta**.

Regressão Linear

Qualidade do Modelo



Com o modelo desenvolvido, o próximo passo é avaliar a **qualidade deste modelo**. Em outras palavras, quanto da variabilidade da variável **Salário** é explicada pelo **modelo**?

$$\text{Salario} = 4.301,80 + 526,73 * \text{Anos de Educacao}$$

Para responder a esta pergunta utilizaremos o **Coeficiente de Determinação**, também conhecido como **R²**. O **R²** mede exatamente quanto da variabilidade da **variável resposta** é explicada pelo **modelo**.

OLS Regression Results

Dep. Variable:	Salario	R-squared:	0.604
Model:	OLS	Adj. R-squared:	0.595
Method:	Least Squares	F-statistic:	67.03
Date:	Wed, 05 Jan 2022	Prob (F-statistic):	2.18e-10
Time:	20:19:45	Log-Likelihood:	-391.36
No. Observations:	46	AIC:	786.7
Df Residuals:	44	BIC:	790.4
Df Model:	1		
Covariance Type:	nonrobust		

O R² do modelo que desenvolvemos é **0,595**.

Logo, o **modelo**, composto pela **variável “Anos de Educação”**, explica **59,5% da variabilidade dos Salários na empresa**.

Ao mostrar esse estudo em uma reunião com a área de RH, um dos gerentes da área de TI fez a seguinte pergunta:

“Se os **Anos de Educação Superior dos funcionários explicam aproximadamente 60% de seus **Salários**, quais são os outros fatores (ou variáveis) que explicam os 40% restantes?”**

Com acesso a **mais variáveis**, podemos construir um **modelo** que **explique mais de 60%** da variabilidade da **variável Salário**.

Regressão Linear

Múltiplas variáveis explicativas



Exemplo dos primeiros 15 funcionários

Após a reunião, a área de RH enviou uma nova base de dados com uma nova variável: **Tempo na Empresa** (em anos).

A pergunta de negócio agora é:

Sabemos que o Salário muda de acordo com os Anos de Educação Superior, mas muda também conforme o Tempo de Empresa? Se sim, é possível construir um modelo que estime o Salário a partir dessas duas variáveis?

Núm. Funcionário	Salario	Anos de Educação Superior	Tempo na Empresa
1	5.517,40	3	3
2	6.399,90	4	6
3	6.206,70	6	3
4	6.060,60	4	5
5	6.122,70	2	9
6	6.955,00	5	9
7	7.643,00	4	6
8	6.210,20	2	8
9	5.761,00	9	15
10	8.086,90	6	14
11	6.375,40	4	9
12	9.568,80	6	20
13	9.316,00	6	25
14	6.822,40	9	18
15	6.570,90	4	19


Regressão Linear

Múltiplas variáveis explicativas




Da mesma forma que fizemos para a variável “Anos de Educação”, vamos **construir um gráfico de dispersão** para a nova variável “Tempo de Empresa”:

Variável Anos de Educação (Correlação = 0,78)



Variável Tempo de Empresa (Correlação = 0,77)




Como ambas as variáveis explicativas **Anos de Educação** e **Tempo de Empresa** apresentam uma relação consideravelmente linear com a variável resposta **Salário**, podemos construir um modelo que estime o **Salário** de um funcionário a partir de seus **Anos de Educação** e **Tempo de Empresa** utilizando a técnica de **Regressão Linear**.

Regressão Linear

Múltiplas variáveis explicativas



Como agora temos no total 3 variáveis: **1 variável resposta** e **2 variáveis explicativas**, a reta não estará mais no plano, e sim em um **espaço tridimensional**, como ilustrado pela animação abaixo:



Regressão Linear

Múltiplas variáveis explicativas



No entanto, a equação do modelo será muito parecida com a que utilizamos anteriormente. O que teremos adicionalmente é um **coeficiente** β_2 associado a nova variável **Tempo de Empresa**:

$$\text{Salario} = \overset{\text{(Intercepto)}}{\beta_0} + \underset{\substack{\text{(Coeficiente} \\ \text{de} \\ \text{Anos de Educação)}}}{\beta_1} * \text{Anos de Educacao} + \underset{\substack{\text{(Coeficiente} \\ \text{de} \\ \text{Tempo de Empresa)}}}{\beta_2} * \text{Tempo de Empresa}$$

Vamos **desenvolver esse modelo** utilizando novamente algumas bibliotecas do **Python**.

Demonstração

Regressão Linear no Python

Arquivo **2_Regressao_Linear_Multipla.zip** contém:

- 2_Regressao_Linear_Multipla.ipynb
- base_funcionarios_v2.csv

Regressão Linear

Múltiplas variáveis explicativas



Vejamos abaixo como interpretar os resultados da regressão linear utilizando o pacote [StatsModels](#):

Este é o R^2 da Regressão. O nome “Adj” (ajustado), vem de uma correção que é feita quanto temos mais de uma variável explicativa no modelo. Podemos concluir que o **acréscimo de uma nova variável aumentou o grau de explicação dos salários de 59,5% para 72,8%.**

OLS Regression Results

Dep. Variable:	Salario	R-squared:	0.740
Model:	OLS	Adj. R-squared:	0.728
Method:	Least Squares	F-statistic:	61.17
Date:	Sun, 02 Aug 2020	Prob (F-statistic):	2.66e-13
Time:	19:13:48	Log-Likelihood:	-381.67
No. Observations:	46	AIC:	769.3
Df Residuals:	43	BIC:	774.8
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
intercepto	4056.0591	309.703	13.097	0.000	3431.483	4680.635
Anos_Educ_Superior	335.3868	66.372	5.053	0.000	201.535	469.238
Tempo_Empresa	117.6566	24.793	4.746	0.000	67.657	167.656

Regressão Linear

Múltiplas variáveis explicativas



OLS Regression Results

Dep. Variable:	Salario	R-squared:	0.740
Model:	OLS	Adj. R-squared:	0.728
Method:	Least Squares	F-statistic:	61.17
Date:	Sun, 02 Aug 2020	Prob (F-statistic):	2.66e-13
Time:	19:13:48	Log-Likelihood:	-381.67
No. Observations:	46	AIC:	769.3
Df Residuals:	43	BIC:	774.8
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
intercepto	4056.0591	309.703	13.097	0.000	3431.483	4680.635
Anos_Educ_Superior	335.3868	66.372	5.053	0.000	201.535	469.238
Tempo_Empresa	117.6566	24.793	4.746	0.000	67.657	167.656

$$\text{Salario} = \beta_0 + \beta_1 * \text{Anos de Educacao} + \beta_2 * \text{Tempo de Empresa}$$

Estes são os coeficientes do modelo completo de regressão.

Regressão Linear

Múltiplas variáveis explicativas



OLS Regression Results

Dep. Variable:	Salario	R-squared:	0.740
Model:	OLS	Adj. R-squared:	0.728
Method:	Least Squares	F-statistic:	61.17
Date:	Sun, 02 Aug 2020	Prob (F-statistic):	2.66e-13
Time:	19:13:48	Log-Likelihood:	-381.67
No. Observations:	46	AIC:	769.3
Df Residuals:	43	BIC:	774.8
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
intercepto	4056.0591	309.703	13.097	0.000	3431.483	4680.635
Anos_Educ_Superior	335.3868	66.372	5.053	0.000	201.535	469.238
Tempo_Empresa	117.6566	24.793	4.746	0.000	67.657	167.656



Estes são os p-valores dos Testes de Hipótese realizados para cada coeficiente. A hipótese nula do teste é que o coeficiente é igual a 0 (zero) na “população”. Como podemos concluir, rejeita-se a hipótese nula de igualdade a 0 (zero) ao nível de significância de 5% e, portanto, **o salário na população é explicado pelos Anos de Educação Superior e Tempo na Empresa.**



Preditiva.ai

Aprendizado Supervisionado

Regressão Linear

Múltiplas variáveis explicativas

Multicolinearidade


Regressão Linear

Multicolinearidade

Quando temos variáveis explicativas que são altamente correlacionadas entre si, o **ajuste** do modelo é comprometido, prejudicando a **estimação dos coeficientes** e a **interpretabilidade do modelo**.



Todas as 3 variáveis explicativas são altamente correlacionadas com o target (Salário)



Tempo de Carreira e Tempo de Empresa **são altamente correlacionadas entre si**, ou seja, existe **Multicolinearidade**.

Regressão Linear

Multicolinearidade



Nesses casos, podemos ter as seguintes consequências para o modelo:

Modelo com **baixa multicolinearidade**

OLS Regression Results						
=====						
Dep. Variable:	Salario	R-squared:	0.740			
Model:	OLS	Adj. R-squared:	0.728			
Method:	Least Squares	F-statistic:	61.17			
Date:	Sun, 02 Aug 2020	Prob (F-statistic):	2.66e-13			
Time:	19:13:48	Log-Likelihood:	-381.67			
No. Observations:	46	AIC:	769.3			
Df Residuals:	43	BIC:	774.8			
Df Model:	2					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

intercepto	4056.0591	309.703	13.097	0.000	3431.483	4680.635
Anos_Educ_Superior	335.3868	66.372	5.053	0.000	201.535	469.238
Tempo_Empresa	117.6566	24.793	4.746	0.000	67.657	167.656

Modelo com **alta multicolinearidade**

OLS Regression Results

Dep. Variable:

Salario

R-squared:

0.742

Model:

OLS

Adj. R-squared:

0.723

Method:

Least Squares

F-statistic:

40.21

Date:

Sun, 09 Aug 2020

Prob (F-statistic):

2.06e-12

Time:

21:00:29

Log-Likelihood:

-381.51

No. Observations:

46

AIC:

771.0

Df Residuals:

42

BIC:

778.3

Df Model:

3

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

intercepto

4060.6182

312.397

12.998

0.000

3430.175

4691.061

Anos_Educ_Superior

335.3325

66.925

5.011

0.000

200.273

470.392

Tempo_Empresa

69.6669

92.205

0.756

0.454

-116.410

255.744

Tempo_de_Carreira

22.9483

42.440

0.541

0.592

-62.699

108.596

Principais efeitos:

1. O modelo mantém ou perde sua performance: R^2 não muda ou diminui.
2. Variáveis que antes importavam para o modelo (p-valor < nível de significância) perdem relevância (p-valor > nível de significância).
3. É possível também que o sinal dos coeficientes fiquem trocados para compensar a multicolinearidade, o que leva a problemas da interpretabilidade do modelo para o negócio.

Regressão Linear

Como tratar a Multicolinearidade?



Preditiva.ai

Modelo com **alta multicolinearidade**

1. Remova uma variável explicativa e ajuste o modelo novamente.

Importante: Realize esse passo com uma variável explicativa de cada vez, pois ao remover uma delas todo o ajuste pode mudar. Ex: Não remover Tempo de Empresa e Tempo de Carreira de uma única vez.

OLS Regression Results						
Dep. Variable:	Salario	R-squared:	0.742			
Model:	OLS	Adj. R-squared:	0.723			
Method:	Least Squares	F-statistic:	40.21			
Date:	Sun, 09 Aug 2020	Prob (F-statistic):	2.06e-12			
Time:	21:00:29	Log-Likelihood:	-381.51			
No. Observations:	46	AIC:	771.0			
Df Residuals:	42	BIC:	778.3			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
intercepto	4060.6182	312.397	12.998	0.000	3430.175	4691.061
Anos_Educ_Superior	335.3325	66.925	5.011	0.000	200.273	470.392
Tempo_Empresa	69.6669	92.205	0.756	0.454	-116.410	255.744
Tempo de Carreira	22.9483	42.440	0.541	0.592	-62.699	108.596

2. Para escolher entre essas variáveis explicativas, preservar considere os seguintes critérios:
 - Variável explicativa com **maior relação de causalidade** com a variável resposta. Ex: As pessoas ganham mais porque têm mais **Tempo de empresa** ou mais **Tempo de carreira**?
 - **Dificuldade de acesso** à variável no momento da implantação do modelo. Ex: **Tempo de empresa** pode ser mais fácil, bastando medir pelo sistema do RH, enquanto o **Tempo de Carreira** pode ser necessário consultar redes sociais ou o colaborador preencher um formulário.
 - Se houver empate nos critérios anteriores, remova a variável explicativa que apresentar **maior p-valor no teste de hipóteses do coeficiente estimado**.

Regressão Linear

Multicolinearidade



Hands on

Resolva um problema de multicolinearidade

Roteiro:

1. Em um novo notebook, importe a base **base_funcionários_v3.csv**.
2. Ajuste um modelo de **regressão linear** para a variável resposta **Salário** utilizando as variáveis explicativas **Anos de Educação Superior**, **Tempo na Empresa** e **Tempo de Carreira**.
3. Avalie a existência de **multicolinearidade**.
4. Selecione e remova uma das variáveis explicativas e ajuste um novo modelo.
5. Interprete os coeficientes do modelo.

Notebook resolvido

3_Regressao_Linear_Multipla_Multicol_Resolvido.zip



Preditiva.ai

Aprendizado Supervisionado

Regressão Linear

Utilizando Variáveis Qualitativas

Regressão Linear

Utilizando variáveis explicativas qualitativas



Como existem muitas **variáveis explicativas qualitativas** (não numéricas), é importante sabermos como podemos incluí-las em um modelo de **Regressão Linear**. Para isso, utilizamos o conceito das **variáveis Dummies**.

Núm. Funcionário	Salario	Anos de Educação Superior	Tempo na Empresa	Possui Skill Dados
1	5.517,40	3	3	Não
2	6.399,90	4	6	Não
3	6.206,70	6	3	Não
4	6.060,60	4	5	Não
5	6.122,70	2	9	Não
6	6.955,00	5	9	Não
7	7.643,00	4	6	Sim
8	6.210,20	2	8	Não
9	5.761,00	9	15	Não
10	8.086,90	6	14	Sim
11	6.375,40	4	9	Não
12	9.568,80	6	20	Sim
13	9.316,00	6	25	Sim
14	6.822,40	9	18	Não
15	6.570,90	4	19	Não

Criando a
variável
Dummy



Núm. Funcionário	Salario	Anos de Educação Superior	Tempo na Empresa	Possui Skill Dados	Possui Skills Dados Dummy
1	5.517,40	3	3	Não	0
2	6.399,90	4	6	Não	0
3	6.206,70	6	3	Não	0
4	6.060,60	4	5	Não	0
5	6.122,70	2	9	Não	0
6	6.955,00	5	9	Não	0
7	7.643,00	4	6	Sim	1
8	6.210,20	2	8	Não	0
9	5.761,00	9	15	Não	0
10	8.086,90	6	14	Sim	1
11	6.375,40	4	9	Não	0
12	9.568,80	6	20	Sim	1
13	9.316,00	6	25	Sim	1
14	6.822,40	9	18	Não	0
15	6.570,90	4	19	Não	0

Regressão Linear

Utilizando variáveis qualitativas



Mas o que fazemos quando temos muitas categorias em uma variável? Basta criar mais variáveis dummies, sendo uma para cada categoria. Veja alguns exemplos:

Escolaridade	Dummies	
	D_Medio	D_Graduacao
Ensino Medio	1	0
Graduação	0	1
Pós Graduação	0	0

Produto	Dummies		
	D_PC	D_Celular	D_TV
PC	1	0	0
Celular	0	1	0
TV	0	0	1
Outros	0	0	0

A **quantidade de variáveis Dummies a serem criadas é sempre N-1**, sendo N a quantidade de categorias da variável explicativa qualitativa.



Vamos ver como podemos criar facilmente essas **variáveis dummies** no Python!



Demonstração

Regressão Linear no Python

Arquivo **4_Regressao_Linear_Multipla_VarQuali.zip** contém:

- 4_Regressao_Linear_Multipla_VariaveisQualitativas.ipynb
- base_funcionarios_v4.csv

Regressão Linear

Utilizando variáveis qualitativas



Preditiva.ai



Hands on

Inclua variáveis qualitativas no modelo

Roteiro:

1. Pratique a construção das variáveis dummy.
2. Ajuste um modelo de **regressão linear** para a variável resposta **Salário** utilizando as variáveis explicativas **Anos de Educação Superior**, **Tempo na Empresa**, **Tempo de Carreira** e **Possui Skill Dados**.
3. Avalie a existência de **multicolinearidade** e faça os devidos tratamentos.
4. Interprete os coeficientes do modelo.

Notebook resolvido

4_Regressao_Linear_Multipla_VarQuali_Resolvido.zip



Preditiva.ai

Aprendizado Supervisionado

Regressão Linear

Diagnóstico do Modelo

Antes de utilizar o modelo de Regressão Linear desenvolvido é importante realizar algumas etapas de diagnóstico para garantir que nenhuma das suposições tenha sido violada.

Suposições mais importantes

- ☐ **Normalidade dos resíduos:** valores dos resíduos devem seguir uma distribuição próxima a Normal.
- ☐ **Resíduos com variância constante** (homoscedasticidade): distância entre os valores estimados e os valores observados (resíduos) deve ser estável.

Interpretação do Modelo

- ☐ **Causalidade ou Associação:** as relações entre as variáveis explicativas e a variável resposta devem fazer sentido do ponto de vista de negócios. Além disso, deve-se avaliar se essas relações são de associação ou causalidade.



Regressão Linear

Diagnóstico do Modelo - Análise dos Resíduos





Os **resíduos do modelo** são a diferença entre os **valores estimados** utilizando os coeficientes do modelo ajustado e os **valores observados**.

Modelo bem ajustado



Modelo mal ajustado



Analisar os **resíduos do modelo** permite identificar se o modelo está **bem ajustado** e se as **premissas não foram violadas**.



Regressão Linear

Diagnóstico do Modelo - Normalidade dos Resíduos





A **normalidade dos resíduos** é importante para avaliar se o **modelo está ajustado de forma não viesada**. Ou seja, os **erros de estimativa** (resíduos) ocorrem de forma **aleatória**, de acordo com uma **distribuição Normal**.

Modelo bem ajustado



Modelo mal ajustado





Regressão Linear

Diagnóstico do Modelo - Homocedasticidade dos Resíduos





Outro fator importante é a **variância dos resíduos**, que deve ser **homogênea**. Ou seja, essa variância não deve mudar de acordo com os valores da variável explicativa.

Modelo bem ajustado



Modelo mal ajustado



Demonstração

Regressão Linear no Python

Arquivo **5_Regressao_Linear_Multipla_Diagnostico.zip** contém:

- 5_Regressao_Linear_Multipla_Diagnostico.ipynb
- base_funcionarios_v2.csv

Regressão Linear

Diagnóstico do Modelo



Hands on

Realize o diagnóstico do modelo desenvolvido com a variável qualitativa Possui Skills Dados.

Roteiro:

1. Recupere o modelo de **regressão linear** desenvolvido com a variável **Possui Skills Dados**.
2. Realize o **diagnóstico** utilizando análise de resíduos.
3. Avalie se as **suposições** do modelo foram violadas.
4. Interprete os coeficientes do modelo.

Notebook resolvido

5_Regressao_Linear_Multipla_Diagnostico_Resolvido.zip



Preditiva.ai