



Preditiva.ai

Aprendizado Supervisionado

Árvores de Decisão



Introdução

Árvores de Decisão

Intuição



Uma técnica **muito versátil** e bastante utilizada para o desenvolvimento de modelos é a das **Árvores de Decisão**. Neste método, as **observações** são sucessivamente **divididas em grupos** (*splits*) de acordo com **suas características**, representadas pelas **features** (variáveis explicativas).




Árvores de Decisão

Intuição



Uma técnica **muito versátil** e bastante utilizada para o desenvolvimento de modelos é a das **Árvores de Decisão**. Neste método, as **observações** são sucessivamente **divididas em grupos** (*splits*) de acordo com **suas características**, representadas pelas **features** (variáveis explicativas).



Dessa forma, as observações com **características parecidas** ficam em um **mesmo grupo**, enquanto observações com **características distintas** ficam em **grupos diferentes**.

Por ser uma técnica de **aprendizado supervisionado**, a forma como as observações são divididas busca exatamente **minimizar o erro** nas estimativas do modelo em relação ao **target** (variável resposta).


Árvores de Decisão

Intuição



Preditiva.ai

A **estrutura** das **Árvores de Decisão** podem influenciar fortemente o **desempenho do modelo** desenvolvido. Mais adiante veremos como escolher os **hiperparâmetros** que definem essa estrutura de forma a obter a **melhor combinação** para cada conjunto de dados.




Árvores de Decisão

Intuição




Uma característica que demonstra muito bem a versatilidade das **Árvores de Decisão** é que podemos utilizar essa técnica para tarefas de **Regressão** (*target* quantitativo) ou **Classificação** (*target* qualitativo), utilizando **features** quantitativas e/ou qualitativas.

REGRESSÃO



CLASSIFICAÇÃO



Árvores de Decisão


Intuição



Apesar de serem uma técnica bastante simples, as **Árvores de Decisão** apresentam algumas **características muito positivas** para o desenvolvimento de modelos.


SIMPLES DE ENTENDER E INTERPRETAR

As regras resultantes das divisões podem ser facilmente entendidas e o modelo facilmente **interpretável**.




REQUER POUCO DATA PREP

Observações com **valores extremos (outliers)** ou **missing values** podem ser simplesmente separadas das demais observações.



ROBUSTA A MULTICOLINEARIDADE

As **features** são selecionadas **individualmente** em cada etapa do **algoritmo de aprendizagem**.




Árvores de Decisão

Intuição

Mas assim como outras técnicas, as **Árvores de Decisão** também possuem **limitações** que podem comprometer a qualidade dos modelos desenvolvidos.


OVERFITTING

O modelo desenvolvido pode ser bastante complexo, fazendo com que ele **perca capacidade de generalização**.



APRENDIZADO POR HEURÍSTICA


Ainda é **computacionalmente inviável** testar todas as possíveis divisões de cada *feature*.



Fonte: https://www.researchgate.net/figure/11-Illustration-of-local-optimum-and-global-optimum_fig16_306558608

INSTÁVEL COM POUCOS DADOS

Mudança em poucas observações pode gerar **alteração das divisões** e modificar o resultado de forma expressiva.



Fonte: <https://www.analyticsvidhya.com/blog/2021/05/25-questions-to-test-your-skills-on-decision-trees>



Preditiva.ai



Preditiva.ai

Aprendizado Supervisionado

Árvores de Decisão

Classificação

Árvores de Decisão

Classificação


Em tarefas de **classificação** o objetivo do algoritmo de **aprendizagem** é **maximizar a separação** entre as diferentes classes do *target* utilizando as *features* disponíveis.

Neste exemplo temos 2 tipos de flores:

- 1: **Orquídeas**
- 0: **Não orquídeas**

A 1ª divisão foi utilizando a *feature* **largura_pétala**. As flores com a **largura_pétala** ≤ 0.8 cm são todas "**não orquídeas**". Logo, a probabilidade de uma flor nesse grupo ser "**não orquídeas**" é de **100%**.

Já as flores com a **largura_pétala** > 0.8 estão misturadas entre "**orquídeas**" e "**não orquídeas**" na proporção de **50%** cada. Ou seja, a probabilidade de uma flor nesse grupo ser "**orquídeas**" é de **50%**.



Árvores de Decisão

Classificação

Em tarefas de **classificação** o objetivo do algoritmo de **aprendizagem** é **maximizar a separação** entre as diferentes classes do *target* utilizando as *features* disponíveis.


Neste exemplo temos 2 tipos de flores:

- 1: **Orquídeas**
- 0: **Não orquídeas**

Na 2ª divisão foi utilizada novamente a feature **largura_petala**.

O grupo de flores com a **largura_petala** ≤ 1.75 cm tem uma concentração maior de "**orquídeas**", e a probabilidade de uma flor nesse grupo ser "**orquídea**" é de **88,9%**.

Já o grupo com a **largura_petala** > 1.75 tem uma concentração maior de "**não orquídeas**". Nesse grupo a probabilidade de uma flor ser "**não orquídeas**" é de **95,7%**.



Árvores de Decisão

Algoritmo CART - *Classification and Regression Trees*



Algoritmo CART para Classificação

1. Seleção de um par (x , s) sendo x uma das **features** disponíveis na base de dados e s um valor para **divisão** usando essa **feature**;
2. Cálculo da **função de erro** conforme abaixo:
 - $$F(x, s) = \frac{\text{qte de observs}_{\text{nó da esquerda}}}{\text{qte de observs do nó superior}} * \text{Impureza}_{\text{nó da esquerda}} + \frac{\text{qte de observs}_{\text{nó da direita}}}{\text{qte de observs do nó superior}} * \text{Impureza}_{\text{nó da direita}}$$
3. Seleção do par (x , s) que **minimiza** a função de erro acima;
4. **Divisão** utilizando o par selecionado e **repetição do processo** até que algum **critério de parada** seja atingido, por exemplo: máxima profundidade, número mínimo de observações por nó, entre outras.

Como medida de **Impureza**, podemos usar as medidas **Gini** ou **Entropia**. Como as duas produzem resultados muito parecidos, a maior parte das bibliotecas escolhem a medida **Gini** por ser mais rápida em ser calculada.

$$\text{Gini} = 1 - \sum_{k=1}^n p_{i,k}^2, \text{ sendo que } p_{i,k} \text{ é a razão da classe "k" pelo total de observações do nó "i".}$$

Demonstração

Árvores de Decisão no Python

Arquivo **1_Arvores_Decisao_Classificacao.zip** contém:

- 1_Arvores_Decisao_Classificacao.ipynb
- aed.py
- iris2.csv

Árvores de Decisão

Probabilidade de Turnover



Hands on

Desenvolva um modelo de **Árvore de Decisão** para identificar o grupo de colaboradores com maior probabilidade de turnover.

Roteiro:

1. Utilize a base de dados **base_rh.csv**;
2. Realize as etapas de **Preparação dos Dados e Análise Exploratória**;
3. Ajuste um modelo de **Árvore de Decisão** para o *target* **Funcionário_deixou_a_empresa** utilizando todas as *features* disponíveis;
4. Avalie o modelo desenvolvido em relação a **interpretabilidade, alinhamento com análise exploratória e desempenho**.
5. Quais perfis de colaboradores possuem **maior probabilidade de deixar a empresa**?

Notebook resolvido

2_Arvores_Decisao_Turnover_Resolvido.zip



Preditiva.ai



Preditiva.ai

Aprendizado Supervisionado

Árvores de Decisão

Regressão

Árvores de Decisão


Regressão



Em tarefas de **regressão** o objetivo do algoritmo de **aprendizagem** é **minimizar o MSE** (*Mean Squared Error*) do modelo utilizando as *features* disponíveis. Neste exemplo queremos estimar o *target* **Salário** do colaborador a partir das *features* **Anos de Educação Superior** e Tempo na Empresa.

Exemplo dos primeiros 15 funcionários

Salario (Y)	Anos de Educação Superior (x ₁)	Tempo na Empresa (x ₂)
5.517,4	3	3
6.399,9	4	6
6.206,7	6	3
6.060,6	4	5
6.122,7	2	9
6.955,0	5	9
7.643,0	4	6
6.210,2	2	8
5.761,0	9	15
8.086,9	6	14
6.375,4	4	9
9.568,8	6	20
9.316,0	6	25
6.822,4	9	18
6.570,9	4	19



Salario (Y)	Anos de Educação Superior (x ₁)	Tempo na Empresa (x ₂)	Salário Estimado pelo modelo
5.517,40	3	3	5.184,68
6.399,90	4	6	6.438,83
6.206,70	6	3	6.438,83
6.060,60	4	5	6.438,83
6.122,70	2	9	5.184,68
6.955,00	5	9	6.438,83
7.643,00	4	6	6.438,83
6.210,20	2	8	5.184,68
5.761,00	9	15	8.009,11
8.086,90	6	14	8.009,11
6.375,40	4	9	6.438,83
9.568,80	6	20	8.009,11
9.316,00	6	25	8.009,11
6.822,40	9	18	8.009,11
6.570,90	4	19	8.009,11

Árvores de Decisão

Algoritmo CART - *Classification and Regression Trees*



Algoritmo CART para Regressão

1. Seleção de um par (x , s) sendo x uma das **features** disponíveis na base de dados e s um valor para **divisão** usando essa **feature**;
2. Cálculo da **função de erro** conforme abaixo:
 - $$F(x, s) = \frac{\text{qte de observs no da esquerda}}{\text{qte de observs do nó superior}} * MSE_{\text{nó da esquerda}} + \frac{\text{qte de observs no da direita}}{\text{qte de observs do nó superior}} * MSE_{\text{nó da direita}}$$
3. Seleção do par (x , s) que **minimiza** a função de erro acima;
4. **Divisão** utilizando o par selecionado e **repetição do processo** até que algum **critério de parada** seja atingido, por exemplo: máxima profundidade, número mínimo de observações por nó, entre outras.

O **MSE** ou **Mean Squared Error** é definido pela equação abaixo, e é muito rápido de ser calculado.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

, sendo y_i é o **valor observado** da i-ésima observação e $\hat{y}_i$ é o **valor estimado** pelo modelo para a i-ésima observação.

Demonstração

Árvores de Decisão no Python

Arquivo **3_Arvores_Decisao_Regressao.zip** contém:

- 3_Arvores_Decisao_Regressao.ipynb
- base_funcionarios.csv

Árvores de Decisão

Salário dos Colaboradores



Hands on

Desenvolva um modelo de **Árvore de Decisão** para estimar o salário dos colaboradores.

Roteiro:

1. Utilize a base de dados **base_funcionários_v4.csv**;
2. Realize as etapas de **Preparação dos Dados e Análise Exploratória**;
3. Ajuste um modelo de **Árvore de Decisão** para o *target* **Salario** utilizando todas as *features* disponíveis;
4. Avalie o modelo desenvolvido em relação a **interpretabilidade, alinhamento com análise exploratória e desempenho**.
5. Quais ***features*** mais influenciam o salário dos colaboradores?

Notebook resolvido

4_Arvores_Decisao_Salario_Resolvido.zip



Preditiva.ai



Preditiva.ai

Aprendizado Supervisionado

Árvores de Decisão

Confiabilidade e

Capacidade de Generalização

Árvores de Decisão


Confiabilidade das Estimativas



Uma característica das **Árvores de Decisão** é que elas podem **explicar totalmente** os dados. Isso porque se não controlarmos alguns de seus **hiperparâmetros**, o processo de divisão em grupos pode chegar ao limite de **cada nó da árvore possuir apenas 1 observação**.

R Quadrado: 0.99

E como sabemos dos fundamentos de **Inferência Estatística**, estimativas utilizando uma **amostra de tamanho igual a 1** apresentam **pouca confiabilidade**!



Árvores de Decisão


Ajuste dos hiperparâmetros



Para evitar esse comportamento devemos definir alguns **hiperparâmetros** que serão utilizados como critério de parada do algoritmo de aprendizagem, que no caso das **Árvores de Decisão** é o **CART**.


PROFUNDIDADE MÁXIMA

Número máximo de **divisões** que serão realizadas no processo de treinamento.




MÍNIMO DE OBSERVAÇÕES POR NÓ

Quantidade **mínima de observações** em um nó para que o algoritmo realize uma **nova divisão**.



MÍNIMO DE OBSERVAÇÕES POR FOLHA

Quantidade **mínima de observações** em uma **folha**.




Árvores de Decisão

Capacidade de Generalização



Além da **Confiabilidade**, quando desenvolvemos **Modelos Preditivos** queremos que os modelos desenvolvidos tenham **também** um **bom desempenho** para classificar ou estimar um valor de observações que **não foram utilizadas** no processo de treinamento. Essa característica é conhecida como **Capacidade de Generalização**.

Avaliar a **Capacidade de Generalização** dos modelos desenvolvidos é **ESSENCIAL!** E para isso vamos utilizar a técnica de **divisão** da base em 2 partes: **Treino e Teste**.



Demonstração

Árvores de Decisão no Python

Arquivo **5_Arvores_Decisao_Generalizacao.zip** contém:

- 5_Arvores_Decisao_Generalizacao.ipynb
- base_funcionarios.csv

Árvores de Decisão

Estimativa de Salário: Confiabilidade e Generalização



Preditiva.ai



Hands on

Explore os hiperparâmetros da Árvore de Decisão e treine um modelo com boa capacidade de Generalização e que ofereça estimativas Confiáveis.

Roteiro:

1. Utilize a base de dados **base_funcionários_v4.csv**;
2. Realize as etapas de **Preparação dos Dados** e **Análise Exploratória**;
3. Treine modelos de **Árvore de Decisão** com diferentes valores de **Profundidade Máxima** (1 a 4) e **Mínimo de Observações por Folha** (1 a 30) e os avalie usando a **divisão** das bases em **Treino** e **Teste**.
4. Armazene em um DataFrame os **hiperparâmetros** utilizados, **R² Treino**, **R² Teste** e calcule a **Diferença** entre R² Teste e R² Treino.
5. Analise os resultados e selecione a combinação de **hiperparâmetros** com maior **confiabilidade** e melhor capacidade de **generalização**.
6. Quais **features** mais influenciam o salário dos colaboradores neste modelo?

Notebook resolvido

6_Arvores_Decisao_Salario_Generalizacao_Resolvido.zip



Preditiva.ai