



Preditiva.ai

Aprendizado Supervisionado

Métodos de Ensemble

Blending


Métodos de Ensemble

Motivação




Existem algumas técnicas de **Machine Learning** muito populares entre os Cientistas de Dados por gerarem ótimos resultados sem ser excessivamente difíceis de utilizar, são as **técnicas de Ensemble de Modelos**. Nessa abordagem, usamos **dois ou mais modelos combinados** para melhorar o desempenho nas tarefas de classificação ou regressão.


Blending



Bagging



Boosting



Métodos de Ensemble

Blending



Métodos de Ensemble


Blending



Para fazermos um **blending** de modelos, usamos as **predições de outros modelos** como **variáveis explicativas** (*features*) para um novo modelo. Esse novo modelo combina então as predições dos outros modelos em uma **única predição**.

Passo 1) Treinamos um modelo inicial utilizando as **features X1, X2** e o **target Y**.

Regressão Logística			
Y	X1	X2	P (Y=1)
0	0	59	0,400
0	1	70	0,120
0	2	40	0,320
0	3	22	0,062
1	5	54	0,930
1	6	30	0,720
1	7	37	0,910
1	8	22	0,954



Passo 2) Treinamos um outro modelo usando o **mesmo Target**. Pode-se mudar as *features* ou mesmo o algoritmo do modelo.


Árvore de Decisão			
Y	X1	X2	P (Y=1)
0	0	59	0,265
0	1	70	0,100
0	2	40	0,185
0	3	22	0,050
1	5	54	0,795
1	6	30	0,585
1	7	37	0,775
1	8	22	0,819

Métodos de Ensemble

Blending



Para fazermos um *blending* de modelos, usamos as **predições de modelos anteriores** como **variáveis explicativas** (*features*) para um novo modelo. Esse novo modelo combina então as predições dos modelos anteriores em uma **única predição**.



Passo 3) Treinamos um novo modelo usando o **mesmo Y como Target e as predições dos modelos anteriores** como variáveis explicativas.

	Regressão Logística	Árvore de Decisão	Modelo <i>Blend</i>
Y	X1 = P (Y=1)	X2 = P (Y=1)	P (Y=1)
0	0,400	0,265	0,130
0	0,120	0,110	0,100
0	0,320	0,185	0,050
0	0,062	0,056	0,050
1	0,930	0,795	0,660
1	0,720	0,585	0,450
1	0,910	0,775	0,640
1	0,954	0,819	0,684

Atenção

Um bom modelo *Blend* deve ter performance superior às performances dos modelos individuais.

Demonstração

Blending de Modelos

Arquivo **1_Ensemble_Blending.zip** contém:

- 1_Ensemble_Blending.ipynb
- iris_original.csv
- preditiva.py

Métodos de Ensemble

Blending - Melhorando o modelo de concessão de crédito



Hands on

Faça um *blending* de modelos para melhorar a predição da concessão de crédito usando o score de um modelo externo

Roteiro:

1. Importe a base **emprestimos.csv** e a divida em treino e teste na proporção 70% e 30% respectivamente;
2. Desenvolva um modelo para estimar a **probabilidade de Default** utilizando essa base e calcule as métricas de desempenho;
3. Importe o arquivo **base_bureaux.xlsx** e utilize a variável **Prob_Bureaux** para desenvolver um **modelo blend**;
4. Calcule o ganho de **AUROC** e **KS** trazido pelo modelo do Bureaux;
5. Esse ganho permite **aumentar a aprovação** com a mesma inadimplência (ou mesmo diminuindo a inadimplência) ?

Notebook resolvido

2_Ensemble_Blending_Emprestimos_Resolvido.zip



Preditiva.ai

Aprendizado Supervisionado


Métodos de Ensemble

Bagging

Métodos de Ensemble

Bagging

Um outro Método de Ensemble de Modelos é o **Bagging**, que consiste em treinar vários **modelos diferentes** com **bases diferentes**. Essas bases são uma amostra aleatória com repetição da base original, tanto em termos de **observações** quanto em termos de **features**.



Modelo 1

Valor Predito = 0.500

Modelo 2

Valor Predito = 0.700

Modelo 3

Valor Predito = 0.600

A **estimativa final** será uma consolidação das estimativas de cada modelo:

Valor Predito Final


$$\frac{(0.500 + 0.700 + 0.600)}{3} = 0.600$$

Métodos de Ensemble

Bagging: Random Forest



Imagine um cenário em que desenvolvemos **100 Árvores de Decisão aleatórias**. Teremos então uma **floresta aleatória** de árvores de decisão, e a estimativa de probabilidade final é a média das estimativas de cada uma dessas árvores. Esse tipo de **Bagging** usando árvores de decisão chama-se **Random Forest**, e é um dos principais métodos de *Machine Learning*.



Cada árvore é treinada com uma parte da base original, em que as **features** e as **observações** são **sorteadas em cada nova base**.

**Predição final
do modelo**
Random Forest

Demonstração

Bagging de Modelos

Arquivo **3_Ensemble_Bagging.zip** contém:

- 3_Ensemble_Bagging.ipynb
- iris_original.csv
- preditiva.py

Métodos de Ensemble

Bagging: Classificando a Renda dos Norte Americanos



Hands on

Compare um modelo de Regressão Logística com o algoritmo Random Forest para classificar a renda (income) dos americanos:

Roteiro:

1. Importe o arquivo `censo_eua.csv`;
2. Desenvolva um modelo de **Regressão Logística** e calcule as métricas de desempenho;
3. Crie um **Bagging** usando **Regressão Logística** e **Random Forest** com 100 estimadores, e calcule as métricas de desempenho;
4. Compare o desempenho dos **diferentes modelos**. Os resultados melhoraram? Explique as hipóteses.

Notebook resolvido

4_Ensemble_Bagging_RendaAmericanos_Resolvido.zip



Preditiva.ai

Aprendizado Supervisionado

Métodos de Ensemble


Boosting

Métodos de Ensemble

Boosting

Diferentemente do método **Bagging**, que treina modelos independentes e depois consolida o resultado desses modelos gerando uma predição final, o método **Boosting** alinha os modelos sequencialmente, de forma que os **erros dos modelos anteriores** são utilizados para **melhorar do modelo final**.

Boosting



Métodos de **Boosting** mais populares:

- AdaBoost
- Gradient Boosting
- XGBoost
- LightGBM
- CatBoost

Métodos de Ensemble


Boosting: AdaBoost



No **AdaBoost** as observações com **maiores erros** tem um **peso maior** atribuído a elas. Dessa forma, o treinamento do próximo modelo buscará reduzir o erro considerando mais as observações com maiores pesos.

Passo 1) Treinamos um **modelo inicial** e calculamos o **erro absoluto**: $y - y_{pred}$. Calculamos então os **pesos** (Weights) de cada observação: $1 + ABS(\text{Erro})$. A forma de calcular os pesos varia de acordo com o método de **Boosting** escolhido.

X1	X2	Y	Modelo 1 P(Y=1)	ABS(Erro)	Weights
0	59	1	0,890	0,110	1,110
1	70	1	0,750	0,250	1,250
2	40	0	0,185	0,185	1,185
3	22	0	0,050	0,050	1,050
5	54	0	0,450	0,450	1,450
6	30	0	0,585	0,585	1,585
7	37	1	0,775	0,225	1,225
8	22	1	0,819	0,181	1,181
Média de erros				0,255	



Passo 2) Um **novo modelo** é treinado considerando os **pesos** (Weights) **do modelo anterior** e dando **mais ênfase** nas observações com os **maiores erros**. Esse processo é repetido sequencialmente até alcançar o **número total de estimadores** definido.

X1	X2	Y	Modelo 2 P(Y=1)	ABS(Erro)	Weights
0	59	1	0,840	0,160	1,160
1	70	1	0,700	0,300	1,300
2	40	0	0,135	0,135	1,135
3	22	0	0,000	0,002	1,002
5	54	0	0,221	0,221	1,221
6	30	0	0,236	0,236	1,236
7	37	1	0,725	0,275	1,275
8	22	1	0,769	0,231	1,231
Média de erros				0,195	

Métodos de Ensemble

Boosting: Gradient Boosting




Outra forma de desenvolver modelos no método **Boosting** é utilizando os **erros residuais**. Nesta abordagem, o **target do novo modelo** é o **erro do modelo anterior**, ou seja, a diferença entre o *target* original e a predição do modelo anterior. O método **Gradient Boosting** é o mais popular desta abordagem.

Passo 1) Treinamos um modelo inicial e calculamos o erro: $y - y_{\text{pred}}$. Esse erro será o **Target** do modelo seguinte.

X1	X2	Y	Modelo 1 P(Y=1)	Erro
0	59	1	0,890	0,110
1	70	1	0,750	0,250
2	40	0	0,185	-0,185
3	22	0	0,050	-0,050
5	54	0	0,450	-0,450
6	30	0	0,585	-0,585
7	37	1	0,775	0,225
8	22	1	0,819	0,181

Média de erros -0,063

Boosting



Passo 2) O novo modelo é treinado com o **target** sendo o **erro do modelo anterior** e as mesmas **features**. Esse processo é repetido sequencialmente até alcançar o **número total de estimadores** definido.

X1	X2	Y	Modelo 2 Erro(Modelo 1)	Erro
0	59	0,11	-0,008	0,118
1	70	0,25	0,027	0,223
2	40	-0,185	-0,069	-0,116
3	22	-0,05	-0,126	0,076
5	54	-0,45	-0,024	-0,426
6	30	-0,585	-0,101	-0,484
7	37	0,225	-0,078	0,303
8	22	0,181	0,170	0,011

Média de erros -0,037

Métodos de Ensemble

Boosting: Gradient Boosting



Outra forma de desenvolver modelos no método **Boosting** é utilizando os **erros residuais**. Nesta abordagem, o **target do novo modelo** é o **erro do modelo anterior**, ou seja, a diferença entre o *target* original e a predição do modelo anterior. O método **Gradient Boosting** é o mais popular desta abordagem.

Passo 1) Treinamos um modelo inicial e calculamos o erro: $y - y_{\text{pred}}$. Esse erro será o **Target** do modelo seguinte.

Passo 2) O novo modelo é treinado com o *target* sendo o **erro do modelo anterior** e as mesmas **features**. Esse processo é repetido sequencialmente até alcançar o **número total de estimadores** definido.

Passo 3) Para fazer a predição final, somamos as predições de cada estimador.
Por exemplo, para a 1ª observação, a predição final será: $0,890 + (-0,008) = 0,882$.

X1	X2	Y	Modelo 1 P(Y=1)	Erro
0	59	1	0,890	0,110
1	70	1	0,750	0,250
2	40	0	0,185	-0,185
3	22	0	0,050	-0,050
5	54	0	0,450	-0,450
6	30	0	0,585	-0,585
7	37	1	0,775	0,225
8	22	1	0,819	0,181

Média de erros -0,063

X1	X2	Y	Modelo 2 Erro(Modelo 1)	Erro
0	59	0,11	-0,008	0,118
1	70	0,25	0,027	0,223
2	40	-0,185	-0,069	-0,116
3	22	-0,05	-0,126	0,076
5	54	-0,45	-0,024	-0,426
6	30	-0,585	-0,101	-0,484
7	37	0,225	-0,078	0,303
8	22	0,181	0,170	0,011

Média de erros -0,037

Y Original	Predito Final
1	0,882
1	0,777
0	0,116
0	-0,076
0	0,426
0	0,484
1	0,697
1	0,989

Demonstração

Boosting de Modelos

Arquivo **5_Ensemble_Boosting.zip** contém:

- 5_Ensemble_Boosting.ipynb
- emprestimos.csv
- preditiva.py

Métodos de Ensemble

Boosting: Identificando vinhos com boas avaliações



Hands on

Utilize os métodos de *Boosting* aprendidos nesta aula para identificar vinhos com boas avaliações:

Roteiro:

1. Importe a base **winequality-red.csv**;
2. Crie a variável **target** com o nome "qualidade", sendo que ela deve assumir valor igual a 1 para vinhos com notas iguais ou maiores do que 7 e zero caso contrário;
3. Desenvolva um modelo utilizando o método **AdaBoost** e outro utilizando o método **Gradient Boosting**. Explore os diversos hiperparâmetros para obter bons modelos;
4. Qual modelo apresentou **melhor desempenho**? Como você **indicaria um bom vinho** utilizando esse modelo?

Notebook resolvido

6_Ensemble_Boosting_Vinhos_Resolvido.zip



Preditiva.ai