



Preditiva.ai

Diagnóstico de Modelos Supervisionados

Acurácia vs. Interpretabilidade


Acurácia vs. Interpretabilidade

O dilema dos Cientistas de Dados



Um dilema constante na vida de um Cientista de Dados é o da **Acurácia vs. Interpretabilidade**. Isso porque diversas técnicas de **Machine Learning** muitas vezes são muito poderosas para capturar uma relação complexa entre as **variáveis explicativas** e o **fenômeno em estudo**, mas não permitem interpretar como essas variáveis estão influenciando o fenômeno.

E saber **como as variáveis influenciam o fenômeno** é **fundamental** para avaliar se o modelo desenvolvido é útil. A seguir vamos ver alguns motivos para interpretarmos sempre o modelo construído.



Predictive power vs. Interpretability dilemma (© ManoMano)

Acurácia vs. Interpretabilidade

O dilema dos Cientistas de Dados



Propagação de vieses

Modelos treinados com **dados que possuem algum viés** como por exemplo discriminação de gênero ou etnia, com certeza **propagarão esse viés**. Na prática, **modelos viesados** são **menos úteis e mais perigosos** de serem utilizados.

Alguns exemplos de casos conhecidos de algoritmos com esse problema:



O dilema dos Cientistas de Dados



Causalidade entre Variáveis Explicativas e Resposta

Um problema no uso dos modelos *Machine Learning* é o **grande número de variáveis explicativas** incluídas muitas vezes **sem** sequer ter sido feita a **análise exploratória adequada** de todas elas.


O que muitas vezes acaba resultando em um modelo que está com um **bom desempenho**, mas talvez **não** necessariamente **pelas causas que você imagina**.




Lobo



Lobo



Cachorro




Cachorro

Acurácia vs. Interpretabilidade

O dilema dos Cientistas de Dados



Vamos ver um exemplo prático de duas técnicas em extremos opostos nas características de **Acurácia** e **Interpretabilidade**: **Regressão Logística** e **Redes Neurais Artificiais**.



Acurácia vs. Interpretabilidade

O dilema dos Cientistas de Dados



Regressão Logística

$$\ln\left(\frac{p}{1-p}\right) = \alpha + \beta_0 \cdot Pclass_1 + \beta_1 \cdot Pclass_2 + \beta_2 \cdot Sex_{of} + \beta_4 \cdot Age$$

▼ OUTPUT - COEFFICIENTS (GLM COEFFICIENTS)

names	coefficients	standardized_coefficients
Intercept	-2.0036	-2.8717
Pclass_cat.1a classe	2.6926	2.6926
Pclass_cat.2a classe	2.1249	2.1249
Pclass_cat.3a classe	0	0
Sex.female	3.3009	3.3009
Sex.male	0	0
Age	-0.0241	-0.3710

Efeitos das variáveis na **probabilidade de sobrevivência**:

- Pclass 1ª classe: **umenta** a probabilidade de sobrevivência em relação a Pclass 3ª classe.
- Pclass 2ª classe: **umenta** a probabilidade de sobrevivência em relação a Pclass 3ª classe.
- Sex female: **umenta** a probabilidade de sobrevivência em relação ao sexo masculino
- Age: maior idade **reduz** a probabilidade de sobrevivência

Acurácia vs. Interpretabilidade

O dilema dos Cientistas de Dados



Redes Neurais Artificiais

Camada 1


Row	Pclass_cat.1a classe	Pclass_cat.2a classe	Pclass_cat.3a classe	Pclass_cat.missing(NA)	Sex.female	Sex.male	Sex.missing(NA)	Age
1	-0.3269	0.3280	-0.4834	-0.6716	0.5539	-0.3795	-0.3326	-0.4575
2	0.1187	0.1189	0.4842	-0.4418	0.4438	-0.4568	-0.5269	-0.2662
3	-0.4617	0.1220	0.0828	-0.2090	0.4672	0.3400	0.3008	-0.0749
4	-0.3485	-0.2715	0.2483	-0.5831	0.6209	-0.3291	0.4162	-0.1262
5	0.3691	0.9000	-0.6626	0.2185	0.3991	-0.3421	0.0265	-0.1334

Camada 2

Row	C1	C2	C3	C4	C5
1	0.5874	-0.5503	-0.0345	0.7745	0.4860
2	-1.4056	0.1270	-0.0430	0.6255	0.4529
3	-0.2271	-0.0489	-0.0792	-0.1789	0.5009
4	0.4299	0.3386	0.6382	-0.4520	0.7088
5	-0.7479	0.6487	0.3984	-0.5814	-0.4446

Camada 3

Row	C1	C2	C3	C4	C5
1	4.9658	-1.1478	-2.2545	-1.0685	0.2350
2	0.9740	-2.3179	-1.2446	3.2962	-3.0628



Os pesos sinápticos não possuem uma interpretação direta.

Eles funcionam como **ponderadores** dos inputs, que após **agregados** são submetidos a uma função da família **sigmóide**.

A utilização de uma função de ativação da família sigmóide proporciona a característica **não-linear**.

Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Como vimos nas **Redes Neurais Artificiais**, diversos outros métodos de ***Machine Learning*** têm características que não permitem que eles sejam facilmente **interpretáveis**.

Por esse motivo, foram desenvolvidas diversas técnicas para entender como as variáveis explicativas influenciam o fenômeno nesses modelos mais complexos:

- **Importância das variáveis**: indica qual a influência de cada variável explicativa.
- **Shapley Values**: indica a contribuição de cada variável para a predição.
- **Dependência parcial**: indica como a variável explicativa interfere na resposta de forma marginal.
- **LIME**: indica como a predição foi realizada para uma data observação.

A seguir vamos aplicar os primeiros dois métodos (os principais) no modelo de **Redes Neurais Artificiais** que desenvolvemos para ver como conseguimos **interpretá-lo, comparando** os resultados com o modelo de **Regressão Logística**.



Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Importância das variáveis

Representa o **nível de influência** de cada **variável explicativa** para a **estimação da variável resposta**. Essa informação é bastante utilizada para fazer também a **seleção de variáveis explicativas**, pois aquelas que apresentam importância muito baixa, ou mesmo zero, podem ser removidas do modelo sem afetar consideravelmente o **desempenho do modelo** e simplificando os cálculos de **otimização dos coeficientes**.





Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Importância das variáveis

Em cada algoritmo a forma de cálculo da importância das variáveis explicativas é feita de uma forma diferente. Na **Regressão Logística** (GLM) a importância é exatamente o **valor absoluto dos coeficientes**, enquanto em **Redes Neurais Artificiais**, no H2O, é utilizado o método proposto por **Gedeon**¹.



Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?




Preditiva.ai

Shapley Values

Utiliza uma abordagem de **Teoria dos Jogos** para explicar os **efeitos das variáveis explicativas** na **predição da variável resposta**.

Duas principais características deste método:

1. **Aditividade**: a soma dos efeitos é igual a diferença entre o **Valor Base** e a **saída do modelo**.
2. **Consistência**: a **ordem** das variáveis explicativas **não altera** a medição dos efeitos.



Acurácia vs. Interpretabilidade


Como interpretar modelos Machine Learning?



Preditiva.ai

Shapley Values: efeitos em 1 observação

Analisando os efeitos das variáveis explicativas na resposta em **uma observação**, temos os seguintes elementos:





Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Shapley Values: efeitos no conjunto dados de teste

É possível também analisar os efeitos das **variáveis explicativas conjuntamente** em um dataset, ou avaliar apenas o efeito de **cada uma das variáveis explicativas**:



Acurácia vs. Interpretabilidade


Como interpretar modelos Machine Learning?




Shapley Values: efeitos no modelo

Por fim, é possível também avaliar o efeito das variáveis no modelo como um todo:

Regressão Logística



Redes Neurais Artificiais



- **Sex:** valores mais altos (1 = Masculino) diminuem a probabilidade de sobrevivência.
- **Age:** valores mais altos diminuem a probabilidade de sobrevivência.
- **Pclass:** valores mais altos (piores classes) diminuem a probabilidade de sobrevivência.

Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Preditiva.ai

Demonstração

Importância das Variáveis e Shapley Values

Arquivo: [Acuracia_Interpretabilidade_Demo.ipynb](#)

Acurácia vs. Interpretabilidade

Como interpretar modelos Machine Learning?



Preditiva.ai



Hands on

Treine um modelo complexo (Random Forest, CatBoost etc) e utilize as **técnicas de interpretação** de modelos para identificar as **features** mais importantes e seus efeitos na **classificação dos bons vinhos**.

Roteiro:

1. Importe a base **winequality-red.csv**
2. Crie a variável resposta **qualidade = 1** para vinhos com notas iguais ou maiores do que 7.
3. Treine um modelo complexo a sua escolha e avalie seu desempenho.
4. Identifique as **features** mais importantes para o modelo.
5. Avalie como essas **features** influenciam a classificação usando o **Shapley Values**.



Preditiva.ai