



Preditiva.ai

Diagnóstico de Modelos

Técnicas de Validação


Técnicas de Validação

Particionamento



Quando desenvolvemos modelos descritivos de ajuste, estamos mais interessados em explicar os dados atuais, e não prever resultados futuros. Caso esta seja a necessidade, precisamos desenvolver modelos com a capacidade de generalização, ou seja, ter bons resultados não só na base em que foram ajustados/treinados, mas em outras bases em que o modelo nunca observou. Essa característica de generalização é obtida através do **particionamento** da base e a devida **validação do modelo**, conforme vemos a seguir.

Processo de Validação do Modelo





Preditiva.ai

Diagnóstico de Modelos

Tipos de validação

Técnicas de Validação


Tipos de validação



Quem estuda essas técnicas muitas vezes têm dúvidas de algumas terminologias comuns como **Validação In Sample**, **Validação Out of Sample**, **Validação Holdout** e algumas outras. De fato, muitas fontes de pesquisa na internet não só trocam os termos como usam termos diferentes para a mesma coisa. Vamos tentar clarificar aqui :

Situação 1

Validação da performance do modelo na mesma base em que foi treinado




Nesta situação, o tipo de validação da performance usada é chamada de **Validação In Sample**, pois a métrica de performance foi medida apenas na amostra (*Sample*) em que o modelo foi treinado.

Técnicas de Validação

Tipos de validação

Situação 2

Validação da performance do modelo em uma partição de teste em que o modelo não foi treinado




Nesta situação, o tipo de validação da performance usada é chamada de **Validação Out of Sample**, pois a métrica de performance foi medida e comparada em mais de uma partição. Na de treino (*Sample*) e na de teste (*Out of Sample*), ou seja, fora da amostra em que o modelo foi treinado.

Técnicas de Validação

Tipos de validação



E quando usamos o modelo treinado para prever um valor de Y em que **não sabemos o valor real**?



Aqui não estamos efetuando nenhuma validação, pois não é possível calcular uma métrica de performance quando não temos a informação do Y Real. Nesta situação, estamos fazendo apenas uma Predição ou **Forecasting** do nosso Y (Target).

Técnicas de Validação


Tipos de validação



Preditiva.ai

Quando trabalhamos com **modelos preditivos**, ou seja, modelos em que o target captura o comportamento de eventos que aconteceram em um tempo futuro ao tempo das variáveis explicativas, utilizamos um tipo de validação chamada **Validação Out of Time (OOT)**. Nesta validação, usamos um determinado período de tempo como treino e outro período futuro para validação (sempre superior ao usado em treino). Veja no diagrama:

Processo de Validação OOT



Obs: É muito comum usar esse tipo de validação no desenvolvimento de modelos em que o Target está em um tempo futuro em relação às variáveis explicativas. Ex: Prever o Churn de Clientes, Prever a Inadimplência de Clientes etc.

Técnicas de Validação

Problemas com a validação

Embora as técnicas de **validação** anteriores parecem fazer sentido e nos ajudar a medir o grau de generalização de nosso modelo, ela **não é perfeita**.

Veja a situação representada ao lado.


Para a mesma “base completa”, **fizemos 3 particionamentos aleatórios e comparamos as métricas R^2** dos modelos de Regressão Linear.

Perceba como as métricas variam de acordo com o particionamento feito.

Para tentar minimizar esse problema, precisamos ir além e estudar outras técnicas de validação: as chamadas **Validações Cruzadas**.



Predictiva.ai





Preditiva.ai

Técnicas de Validação

Validação Cruzada

Técnicas de Validação

Validação Cruzada




Predictiva.ai

Como falamos anteriormente, o problema do particionamento é que as métricas mudam de acordo com o particionamento realizado.

Como o particionamento de Treino e Teste é realizado de forma aleatória, **a cada vez que o código é rodado um novo particionamento é realizado**, o que gera um novo modelo e novas métricas de performance em treino e teste.

Precisamos de um método que nos dê uma boa noção do grau de generalização de nosso modelo e que leve em consideração a questão da aleatoriedade do particionamento.

Para isso podemos usar as chamadas técnicas de **Validação Cruzada (Cross Validation)**.



Validação Cruzada

K-Fold



Neste tipo de validação cruzada, particionamos a base em K partes de mesmo tamanho sendo que **K-1 partes são usadas para Treino** e **uma parte é usada para Teste**. A ideia dessa técnica é que ao treinarmos o modelo em mais partes diferentes podemos diminuir o problema da variabilidade das métricas de performance. Veja:

K-Fold (sendo K = 5)

	Base Completa					R ² (Treino)	R ² (Teste)
Split 1	Treino	Treino	Treino	Treino	Teste	0,83	0,82
Split 2	Treino	Treino	Treino	Teste	Treino	0,82	0,81
Split 3	Treino	Treino	Teste	Treino	Treino	0,81	0,82
Split 4	Treino	Teste	Treino	Treino	Treino	0,85	0,87
Split 5	Teste	Treino	Treino	Treino	Treino	0,86	0,84
	Média					0,834	0,832

Com o **K-Fold** olhamos a média das métricas entre todos os treinamentos de modelo realizados nos particionamentos.

Desta forma, em vez de comparar apenas uma métrica de treino e teste, comparamos o comportamento geral dos modelos treinados a cada particionamento.

Técnicas de Validação

Validação Cruzada na Base de RH



Hands on

Treine um modelo usando validação cruzada e compare o ROC em treino e teste.

Roteiro:

1. Importe a base “base_rh.csv”;
2. Separe a base em treino e teste usando 70% de treino e 30% de teste;
3. Treine um modelo e compare os resultados em treino e teste;
4. Utilize Validação Cruzada K-Fold para verificar o AUC médio do modelo.
5. O resultado em teste ficou muito diferente da Validação Out of Sample (item 3)?



Preditiva.ai