



Preditiva.ai

# Diagnóstico de Modelos

## *Overfitting e Underfitting*

# Diagnóstico de Modelos

## Overfitting e Underfitting




Preditiva.ai

Quando desenvolvemos modelos estamos interessados em utilizá-los para **fazer previsões** em **novas bases de dados**, diferentes daquelas utilizadas no processo de treinamento. E para avaliar se essas previsões serão adequadas precisamos avaliar a **capacidade de generalização** dos modelos. Para isso, vamos aprender os conceitos: *Overfitting* e *Underfitting*.

### *Underfitting* ("Bias problem")


Poucas variáveis e/ou modelo muito simplificado para explicar o target



$$y = \beta_0 + \beta_1 * x$$

### Modelo Ideal


Variáveis e complexidade do modelo adequadas para explicar o target



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2$$

### *Overfitting* ("Variance problem")

Muitas variáveis e/ou modelo muito complexo para explicar o target



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2 + \beta_3 * x^3$$

# Diagnóstico de Modelos

## *Underfitting*



Um modelo com ***Underfitting*** apresenta **baixo desempenho** em qualquer base de dados. Isso é causado principalmente pela falta de capacidade em capturar as **relações** entre as **features** (variáveis explicativas) e o **target** (variável resposta).

### CONSEQUÊNCIAS

**Baixo desempenho** do modelo em qualquer base de dados.

### DIAGNÓSTICO

Avaliação do modelo utilizando as **métricas de performance** de classificação ou regressão.

### TRATAMENTOS

- Seleção de **algoritmos** mais adequados aos dados: **linear vs. não linear**.
- Inclusão de novas **features** ou utilização de técnicas de **feature engineering**.

# Diagnóstico de Modelos

## *Overfitting*



Um modelo com ***Overfitting*** tem uma baixa **capacidade de generalização**. Isso significa que seu **desempenho de predição** em uma base não utilizada no treinamento será **pior** do que o desempenho observado no conjunto de treino.

### CONSEQUÊNCIAS

**Perda de desempenho** do modelo em bases de dados não utilizadas no treinamento.

### DIAGNÓSTICO

Avaliação do modelo utilizando técnicas de **Validação Cruzada**, como por exemplo a divisão da base em **Treino e Teste**.

### TRATAMENTOS

- Redução da **complexidade** do modelo utilizando técnicas de **Regularização**.
- Redução do número de **features** utilizadas.



Preditiva.ai

# Diagnóstico de Modelos Técnicas de Regularização


# Diagnóstico de Modelos

## Regularização




Preditiva.ai

Vamos apresentar o conceito de **Regularização** utilizando o exemplo de modelo com **Overfitting** visto anteriormente. Podemos observar que quando incluímos a **variável  $x^3$** , obtivemos um modelo com **Overfitting**.



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2$$

Adicionando  
a variável  $x^3$



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2 + \beta_3 * x^3$$


# Diagnóstico de Modelos

## Regularização




Preditiva.ai

Para resolver esse problema, vamos aplicar as técnicas de **Regularização** que visam simplificar o modelo. Dessa forma, teremos um modelo com melhor **capacidade de generalização**.



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2 + \beta_3 * x^3$$

Diminuindo o  
efeito do  
coeficiente  $\beta_3$



$$y = \beta_0 + \beta_1 * x + \beta_2 * x^2 + 0,00001 * x^3$$

Atribuindo **menos peso** a algumas variáveis tornamos o **modelo mais simples** e reduzimos o **Overfitting**.

# Demonstração

## Regularização de Árvores de Decisão

Arquivo **1\_Regularizacao\_Arvores\_Decisao.zip** contém:

- 1\_Regularizacao\_Arvores\_Decisao.ipynb
- preditiva.py
- emprestimos.csv



# Diagnóstico de Modelos

## Regularização



**Antes da Regularização** observamos uma **queda de desempenho** bastante expressiva em diversas métricas, comparando Treino e Teste. **Após a Regularização**, além de obtermos uma **variação muito menor**, as métricas **AUROC** e **KS** apresentaram um **aumento de desempenho considerável no conjunto de Teste**.

Antes da Regularização

|           | Treino | Teste    | Variação |
|-----------|--------|----------|----------|
| Acurácia  | 1.0    | 0.703333 | -0.30    |
| AUROC     | 1.0    | 0.628871 | -0.37    |
| KS        | 1.0    | 0.257742 | -0.74    |
| Precision | 1.0    | 0.512821 | -0.49    |
| Recall    | 1.0    | 0.439560 | -0.56    |
| F1        | 1.0    | 0.473373 | -0.53    |

Aplicando  
Técnicas de  
Regularização



Após a Regularização

|           | Treino   | Teste    | Variação |
|-----------|----------|----------|----------|
| Acurácia  | 0.771429 | 0.710000 | -0.08    |
| AUROC     | 0.806556 | 0.701667 | -0.13    |
| KS        | 0.435290 | 0.334718 | -0.23    |
| Precision | 0.641618 | 0.529412 | -0.17    |
| Recall    | 0.531100 | 0.395604 | -0.26    |
| F1        | 0.581152 | 0.452830 | -0.22    |

# Diagnóstico de Modelos


## Regularização em Algoritmos da família Árvore de Decisão



Nas **Árvores de Decisão** a regularização é feita ajustando os seguintes **hiperparâmetros**:

Profundidade máxima:  
**max\_depth**

**Reduzir** a profundidade máxima reduz a complexidade do modelo



Mínimo de observações para divisão: **min\_samples\_split**

**Aumentar** o número mínimo de observações **limita o crescimento da árvore**

Mínimo de observações por folha: **min\_samples\_leaf**

**Aumentar** o número mínimo de observações **limita o crescimento da árvore**

# Diagnóstico de Modelos

## Probabilidade de Default: Regularização



## Hands on

Aplique as técnicas de Regularização em um modelo de Árvore de Decisão e compare com um modelo de Regressão Logística.

Roteiro:

1. Utilize a base de dados **emprestimos.csv**;
2. Realize as etapas de **Preparação dos Dados e Análise Exploratória**;
3. Divida a base em **Treino** e **Teste** na proporção **70%** e **30%** e treine modelos de **Árvore de Decisão** com diferentes valores de **Profundidade Máxima** e **Mínimo de Observações por Folha**.
4. Armazene em um DataFrame os **hiperparâmetros** utilizados e as métricas de desempenho, incluindo a **Variação** entre **Treino** e **Teste**.
5. Analise os resultados e selecione a combinação de **hiperparâmetros** com menor **Overfitting** e maior **desempenho**.
6. Ajuste um modelo de **Regressão Logística** e compare os **resultados** de desempenho e sua variação com o modelo de **Árvore de Decisão** selecionado. **Qual modelo é melhor?**

**Notebook resolvido**

**2\_Regularizacao\_Arvores\_Decisao\_Default\_Resolvido.zip**



Preditiva.ai