



Preditiva.ai

# Diagnóstico de Modelos Supervisionados

## Tuning de Hiperparâmetros

# Tuning de Hiperparâmetros


Por que temos tantos hiperparâmetros para ajustar?



Os modelos de **Machine Learning**, como vimos anteriormente, podem possuir diversos **hiperparâmetros** e ajustá-los corretamente pode fazer muita diferença no **desempenho**.

Mas antes, vamos entender quais as diferenças entre os parâmetros e **hiperparâmetros**:

- **Parâmetros:** também conhecidos como **coeficientes**, são os elementos otimizados durante o treinamento e são responsáveis por **capturar o conhecimento** contido nos dados.
- **Hiperparâmetros:** são responsáveis pela **definição da estrutura do modelo**. Cada técnica possuirá diferentes **hiperparâmetros** que permitem uma **adequação da estrutura** do modelo para **melhor adequação** aos dados.



Fonte: <http://www.radixeng.com.br/noticias/599/machine-learning-uma-tendencia-que-nao-pode-ser-ignorada>

# Tuning de Hiperparâmetros

Por que temos tantos hiperparâmetros para ajustar?



Abaixo, temos alguns dos muitos **hiperparâmetros** de cada uma das técnicas mais populares:

## Redes Neurais Artificiais

- Nº camadas
- Nº neurônios por camada
- Função de ativação
- Taxa de dropout
- L1 e L2
- Otimizador
- Learning rate

## Árvores de Decisão

- Max depth
- Critério para split
- Min samples split
- Max features split

## Naive Bayes

- Priori

## Support Vector Machine

- Kernel
- Degree
- C

## Gradient Boosting Machine

- Nº estimadores
- Max depth
- Learning rate
- Critério para split
- Min samples split
- Max features split

## XGBoost

- Learning rate
- Gamma
- Max depth
- Min child weight
- Max delta step
- L1 e L2

# Tuning de Hiperparâmetros

Por que temos tantos hiperparâmetros para ajustar?



Vamos analisar o número de diferentes combinações dos **hiperparâmetros** em uma Rede Neural Artificial:

| Hiperparâmetro          | Valores permitidos                                                     | Nº alternativas |
|-------------------------|------------------------------------------------------------------------|-----------------|
| Nº camadas              | Inteiro: 1 a 5                                                         | 5               |
| Nº neurônios por camada | Inteiro: 1 a 16                                                        | 16              |
| Função de ativação      | Categórico: 1 - Relu; 2 - Sigmoid; 3 - Tanh; 4 - Softmax               | 4               |
| Taxa de dropout         | Real: 0% a 80%                                                         | 9               |
| L1                      | Real: 0,0 a 0,1                                                        | 20              |
| L2                      | Real: 0,0 a 0,1                                                        | 20              |
| Otimizador              | Categórico: 1 - Adam; 2 - Adadelata; 3 - Adagrad; 4 - SGD; 5 - RMSprop | 5               |
| Learning rate           | Real: 0,0001 a 0,0100                                                  | 100             |

Mesmo considerando apenas os **hiperparâmetros mais importantes**, o número de **combinações chega a 576 mil**. Se o tempo necessário para treinar cada modelo for de **1 segundo**, serão necessários mais de **18 anos** para testar todas as possibilidades!

# Tuning de Hiperparâmetros

## Principais estratégias



Desde então tem-se buscado diferentes estratégias para **explorar** esse **grande número de combinações** da forma mais **eficiente** possível, ou seja, avaliando **poucas combinações** e conseguindo **grande desempenho**.

| Método               | Característica principal                                              | Pontos Fortes                                                             | Pontos Fracos                                                  |
|----------------------|-----------------------------------------------------------------------|---------------------------------------------------------------------------|----------------------------------------------------------------|
| Random Search        | Exploração <b>aleatória</b> do espaço hiperparamétrico                | Fácil compreensão do método                                               | Não considera regiões que possam produzir melhores resultados  |
| Grid Search          | Exploração <b>extensiva</b> do espaço hiperparamétrico                | Testa todas as combinações no espaço definido                             | Pode gerar uma grande quantidade de modelos para avaliação     |
| Otimização Bayesiana | Exploração <b>guiada</b> do espaço hiperparamétrico                   | Utiliza resultado das escolhas anteriores para selecionar hiperparâmetros | Capacidade limitada de explorar todo o espaço hiperparamétrico |
| Algoritmos Genéticos | Inspirado na Teoria de <b>Evolução das Espécies</b> de Charles Darwin | Considera regiões com melhor resultado para maior exploração              | Pode requerer uma grande quantidade de modelos para avaliação  |


# Tuning de Hiperparâmetros

## Principais estratégias: Random Search



### Random Search

Neste método, o **espaço hiperparamétrico** é explorado forma **aleatória**. Ou seja, são treinados diversos modelos com diferentes hiperparâmetros selecionados aleatoriamente e no final compara-se o desempenho de todos eles.



| Nº de camadas | Nº neurônios por camada | RMSE Test |
|---------------|-------------------------|-----------|
| 1             | 1                       | 1,24      |
| 1             | 4                       | 1,32      |
| 2             | 2                       | 1,12      |
| 2             | 3                       | 2,10      |
| 3             | 1                       | 0,95      |
| 3             | 2                       | 0,82      |
| 3             | 5                       | 0,91      |

# Demonstração

## Random Search

Arquivo: [6\\_Tuning\\_Hiperparametros.ipynb](#)


# Tuning de Hiperparâmetros

## Principais estratégias: Grid Search



### Grid Search

Este é um dos métodos ainda muito utilizados, e consiste em **explorar** extensivamente **todas as combinações** de hiperparâmetros no **espaço definido**. Dependendo do número do espaço definido, o número de modelos a serem explorados pode ser bastante grande.



| Nº de camadas | Nº neurônios por camada | RMSE Test |
|---------------|-------------------------|-----------|
| 1             | 1                       | 2,18      |
| 1             | 2                       | 2,15      |
| 1             | 3                       | 2,43      |
| ...           | ...                     | ...       |
| 2             | 4                       | 0,79      |
| ...           | ...                     | ...       |
| 3             | 5                       | 1,56      |



# Demonstração

## Grid Search

Arquivo: [6\\_Tuning\\_Hiperparametros.ipynb](#)


# Tuning de Hiperparâmetros

## Principais estratégias: Bayesian Optimization



### Bayesian Optimization

Este método tem como principal vantagem a **escolha dos próximos hiperparâmetros** a serem testados a partir dos **resultados obtidos anteriormente**.



| Nº de camadas | Nº neurônios por camada | RMSE Test |
|---------------|-------------------------|-----------|
| 1             | 3                       | 2,18      |
| 2             | 3                       | 2,15      |
| 1             | 4                       | 2,43      |
| ...           | ...                     | ...       |
| 2             | 4                       | 0,79      |
| ...           | ...                     | ...       |
| 3             | 5                       | 1,56      |


# Tuning de Hiperparâmetros

## Principais estratégias: Bayesian Optimization



### Bayesian Optimization

Este método tem como principal vantagem a **escolha dos próximos hiperparâmetros** a serem testados a partir dos **resultados obtidos anteriormente**.



# Demonstração

## Bayesian Optimization

Arquivo: [6\\_Tuning\\_Hiperparametros.ipynb](#)

# Tuning de Hiperparâmetros

## Principais estratégias



## Hands on

Utilize as técnicas de tuning de hiperparâmetros aprendidas nesta aula para melhorar o desempenho do modelo usando a mesma base de Preços de Casas porém com um modelo mais simples, como o **Random Forest**.

Roteiro:

1. Identifique e selecione alguns dos **hiperparâmetros** para realização do **tuning**. Sugestão: `max_depth`, `min_samples_split` e `n_estimators`.
2. Utilize o `random_state = 42`.
3. Defina o **espaço paramétrico** para cada um dos hiperparâmetros.
4. Utilize algum dos **métodos de tuning** de hiperparâmetros para obter um modelo com **melhor desempenho** no conjunto de teste.

# Revisão: Tuning de Hiperparâmetros

Neste módulo vimos que os modelos de **Machine Learning** tem **muitos hiperparâmetros** para serem otimizados e o **ajuste adequado** pode trazer um grande **ganho de desempenho**.

Aprendemos as técnicas mais populares utilizadas no tuning dos hiperparâmetros: **Random Search**, **Grid Search** e **Bayesian Optimization**, cada um deles com vantagens e desvantagens, e diferentes estratégias para **explorar de forma eficiente** o espaço hiperparamétrico.





Preditiva.ai