



Preditiva.ai

Aplicação

Classificação de dados desbalanceados - Saúde

Case

O problema de negócio



Você trabalha na **KidneyCare**, uma rede de hospitais focada em tratamentos de doenças ligadas ao rim, e está trabalhando em um problema de **detecção de casos de CKD** (Chronic Kidney Disease). Se não tratada, essa doença pode levar os rins a não filtrar corretamente o sangue. Em estados avançados, pode causar a falha do órgão, fazendo-se necessário um transplante ou hemodiálise. Você sabe que identificar os pacientes de maneira antecipada pode levar a um melhor tratamento, melhorando as condições de vida. Ao mesmo tempo, custo e tempo é um fator importante, precisamos evitar de encaminhar casos incertos em excesso, pois isso tem um custo elevado de franquia a sua empresa.

Seu objetivo é construir um modelo de **classificação** que suporte os médicos a identificar os pacientes com risco de doença, de maneira e encaminha-los para uma bateria de exames posterior.




O que é um problema de classificação?

O que vamos resolver?



No case em questão, precisamos identificar a que **classe uma pessoa pertence**: **Paciente Saudável ou com CDK**. Sempre que temos que classificar algo, seja isso uma pessoa, um objeto, um arquivo, um comentário, um animal, uma ação, sentimento ou qualquer outra coisa, estamos tratando de um problema de **classificação**! Eles são muito utilizados por empresas dos mais diversos setores, sendo casos como a predição de doenças (o case em questão) ou finanças, sendo a detecção de transações fraudulentas um case bem documentado!


Dentro da classificação podemos diferenciar diversos subtipos de projetos. Se é um projeto de **classificação binária**, onde só temos **2 classes** a serem preditas (Classificação de um e-mail como spam ou não, detecção de uma atividade fraudulenta) ou **multiclasse**, onde podemos ter diversas classes. Um bom exemplo desse caso é a **análise de sentimento**, onde um comentário pode representar felicidade, tristeza, raiva, ansiedade, alívio etc.





Classificação de imagens



Deteção de Fraude



Deteção de câncer de pele



Análise de sentimento


O que é o desbalanceamento?

O mundo real não é perfeito

Em cenários reais, quase sempre os dados **NÃO** vão estar balanceados.

O que isso quer dizer? Que normalmente uma classe sempre vai se sobrepor a outra em quantidade de registros. Obviamente, essa quantidade desigual vai depender de caso a caso: Em algumas situação estamos falando de uma proporção 40%:60%, como quando estamos avaliando um se um comentário em uma loja online é positivo ou negativo. Mas outras situações, as proporções podem ser de **99:1**, como **detecção de fraude de cartão de credito**, onde a grande maioria das transações são normais!

Quando esse cenário muda, precisamos **mudar também a forma com a qual construímos e avaliamos os nossos modelos**! As métricas mais conhecidas, **aqui já não tem tanto peso**. Vamos avaliar isso mais a frente, por enquanto, vamos ver como os dados que temos estão **distribuídos**!



92% dos dados são de pacientes normais. Apenas **8% dos registros são de pacientes com CKD**! Identifica-los de forma prematura é nossa **prioridade**




Quais métricas usar?

E quais métricas não usar!

Para problemas de classificação a métrica mais conhecida é a **acurácia**!

Porém, ela **não é a melhor métrica** para nosso problema em questão!! Quer um exemplo disso: Imagine que disséssemos que **nenhum** paciente está doente, mesmo errando todos os casos de doença, ainda teria incríveis **92% de acurácia**! Além disso, não adianta nada acertar todos os casos de pacientes saudáveis e errar **todos** os pacientes doentes, justamente por este último grupo ser nosso caso de **FOCO**!

$$\text{Acurácia} = 1524/1659 = 92\%$$



Percentual classe minoritária	Grau
20 - 40%	Baixo
01 - 20 %	Médio
00 – 01%	Alto


Quais métricas usar?

Matriz de Confusão



Uma das primeiras coisas que devemos avaliar quando construímos um modelo de classificação, independente das classes estarem desbalanceadas ou não, é a **matriz de confusão**! Ela nos dá um overview de como os **dados foram classificados e se estamos indo bem ou mal**. A matriz possui 4 quadrantes:


- Verdadeiro Positivo: Caso de CDK predito corretamente
- Verdadeiro Negativo: Paciente normal, predito como Normal
- Falso Positivo: Paciente normal, predito com CDK
- Falso Negativo: Paciente com CDK, predito normal



Quais métricas usar?

Matriz de Confusão

Uma outra dica, sempre que plotar uma matriz de confusão, tente plotar também a matriz de confusão balanceada, os valores ficam mais coerentes e entendíveis.



Quais métricas usar?

Recall, Precisão, F1-score e F Beta-score, Acurácia Balanceada



Preditiva.ai

Recall: Quantidade de casos positivos preditos versus quantidade total de casos positivos que aconteceram

$$\text{Recall} = \frac{TP}{(TP+FN)} = \frac{6}{6+35} = \mathbf{14\%}$$

Precisão: Quantidade de casos positivos preditos versus quantidade de casos positivos preditos

$$\text{Precisão} = \frac{TP}{(TP+FP)} = \frac{6}{6+5} = \mathbf{54\%}$$

F1-score: É a média harmônica entre a precisão e recall, mede um equilíbrio entre as duas métricas

$$\text{F1-score} = \frac{1}{\text{Recall}} + \frac{1}{\text{Precisão}} = \frac{2 \times \text{Recall} \times \text{Precisão}}{\text{Recall} + \text{Precisão}} = \frac{2 \times 0.14 \times 0.54}{0.14 + 0.54} = \mathbf{23\%}$$

F Beta-score: É uma variação do F1-score, que te permite dar mais peso ao Recall ou a Precisão. Beta maior que 1 da foco ao recall, beta menor que 1 da foco na precisão.

$$\text{F2-score} = \frac{(\beta^2+1) \times \text{Recall} \times \text{Precisão}}{\beta^2 \times \text{Precisão} + \text{Recall}} = \frac{(2^2+1) \times 0.14 \times 0.54}{2^2 \times 0.54 + 0.14} = \mathbf{16\%}$$

$$\text{F0.5-score} = \frac{(\beta^2+1) \times \text{Recall} \times \text{Precisão}}{\beta^2 \times \text{Precisão} + \text{Recall}} = \frac{(0.5^2+1) \times 0.14 \times 0.54}{0.5^2 \times 0.54 + 0.14} = \mathbf{34\%}$$

Acurácia Balanceada: É uma formula equivalente a acurácia, mas bota pesos iguais em ambas as classes.

$$\text{Acurácia Balanceada} = \frac{1}{2} * \left(\frac{TP}{TP+FN} + \frac{TN}{TN+FP} \right) = \frac{1}{2} * \left(\frac{6}{6+35} + \frac{452}{452+5} \right) = \frac{1}{2} * (0.14 + 0.98) = \mathbf{56\%}$$

TN	0	452	5	FP
FN	1	35	6	TP
		0	1	


Prevendo Classes?

Como flexibilizar previsões!




Apesar de as classes serem 0 ou 1, na maioria das situações isso **precisa** ser mais flexível. Em contextos de negócio reais, é sempre importante estimar uma **probabilidade** a **cada observação avaliada**!

Felizmente, para boa parte dos modelos de classificação, além da predição em si, podemos fazer também a **predição de probabilidades**! Por padrão, os modelos estabelecem uma seguinte regra: Se uma observação tem mais que **50% de probabilidade**, ela fica associada a classe 1. Caso contrário, fica associado a classe zero.




Previsão de Probabilidades

Fronteiras de decisão – Recall vs Previsão



Previsão de Probabilidades


Fronteiras de decisão



Aumentar a precisão, diminui o recall

Previsão de Probabilidades

Fronteiras de decisão



Aumentar o recall, diminui a precisão


Trade Off Precisão-Recall

Curva Precisão e Recall



Em problemas de classificação temos o que chamamos de **trade off de precisão e recall**. Isso acontece pois, se aumentamos o recall, variando o valor do limiar de decisão, a tendência da precisão é diminuir.

O oposto também é verdade, quando a precisão aumenta, o recall diminui. É nosso trabalho, como cientista de dados e entendedores da área de negócio decidir qual é a **melhor combinação** de valores possíveis!





Técnicas Balanceamento

Oversampling



Preditiva.ai



- Classe 1
- ▲ Classe 0



Técnicas Balanceamento

Undersampling

● Classe 1
▲ Classe 0



Class Weight e Threshold Selection




Os melhores caminhos

O Oversampling e Undersampling ainda são técnicas usadas, mas há um debate saudável sobre a sua aplicação. Com o desenvolvimento de modelos mais modernos, principalmente os **baseados em árvores**, as técnicas de contorno para situação de desbalanceamento entre classes mudaram!

Hoje, podemos escolher por dois caminhos principais e nosso case prático vai fazer a avaliação de ambos! São eles: **Class Weight**, ou peso de classes e **Threshold selection**, ou escolha do limiar de decisão. Isso, somado a utilização de **modelos mais modernos (boosting)**, tem muito a agregar em nossa predição.

O class weight olha a proporção entre a classe positiva e negativa e dá pesos proporcional a elas durante o **ajuste**! Dito isso, errar um caso 0 tem um peso MUITO menor do que errar um caso 1. Então, o modelo vai prestar muito mais atenção nas classes de interesse.



Já o Threshold Selection é algo que já debatemos anteriormente. Com o modelo usual, fazer a melhor escolha possível de limiar de decisão que atenda às necessidades da área de negócio!

