



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Introdução


Processamento de Linguagem Natural

Introdução



A utilização de **dados não estruturados** vem aumentando muito nos últimos anos, principalmente com o aumento do poder computacional e informações disponíveis nesse formato.

O **Processamento de Linguagem Natural** ou *Natural Language Processing* - **NLP** é uma grande área que integra os conhecimentos de **linguística**, **computação** e **inteligência artificial**, e estuda os padrões existentes nas interações em **linguagem natural**.



Processamento de Linguagem Natural


Introdução



Preditiva.ai

Em 1950 Alan Turing publicou um artigo com o título "***Computing Machinery and Intelligence***" no qual ele propõe o chamado **Teste de Turing**.

Neste teste, Turing propõe uma tarefa que envolve a interpretação e geração de linguagem natural como um indicador de que as máquinas alcançaram o nível de inteligência humana.



Fonte: <https://medium.com/@jetnew/a-summary-of-alan-m-turings-computing-machinery-and-intelligence-fd714d187c0b>

Processamento de Linguagem Natural

Introdução



Entre **1950 e 1990** as técnicas de NLP eram fortemente **baseadas em regras**. O primeiro chatbot chamado **ELIZA** foi construído por Joseph Weizenbaum do laboratório de IA do MIT entre 1964 e 1966.

Entre **1990 e 2010** as técnicas evoluíram para utilização de **métodos estatísticos e aprendizado de máquina**, e o aumento do volume de dados não rotulados gerou também uma expansão dos métodos não supervisionados em texto.

```
Welcome to
EEEEEE LL      IIII ZZZZZZZ  AAAA
EE      LL      II      ZZ  AA  AA
EEEEEE LL      II      ZZZ  AAAAAA
EE      LL      II      ZZ  AA  AA
EEEEEE LLLLLL IIII ZZZZZZZ  AA  AA

Eliza is a mock Rogerian psychotherapist.
The original program was described by Joseph Weizenbaum in 1966.
This implementation by Norbert Landsteiner 2005.

ELIZA: Is something troubling you ?
YOU:   Men are all alike.
ELIZA: What is the connection, do you suppose ?
YOU:   They're always bugging us about something or other.
ELIZA: Can you think of a specific example ?
YOU:   Well, my boyfriend made me come here.
ELIZA: Is it important to you that your boyfriend made you come here ?
YOU:   He says I'm depressed much of the time.
ELIZA: I am sorry to hear that you are depressed.
YOU:   It's true. I am unhappy.
ELIZA: Can you explain what made you unhappy ?
YOU:   █
```

Fonte: <https://pt.wikipedia.org/wiki/ELIZA>


Processamento de Linguagem Natural

Introdução




A partir de 2010 o NLP começou a utilizar mais intensamente as **Redes Neurais Artificiais**, que são consideradas até hoje o estado da arte em diversas aplicações.

Redes Neurais Recorrentes (LSTM)



Fonte: <http://phontron.com/class/nn4nlp2021/assets/slides/nn4nlp-07-attention.pdf>

Redes Neurais Convolucionais (CNN)



Fonte: <https://arxiv.org/pdf/1703.03091.pdf>


Processamento de Linguagem Natural

Introdução



As técnicas de **NLP** possuem diversas aplicações, mas as mais comuns são:

- Speech Recognition
- Análise de Sentimentos
- Recursos de **auto completar** em celulares
- **Extração automática de tópicos** em grandes quantidades de texto
- **Sumarização automática** de textos
- Sistemas de interação como **chatbots e assistentes virtuais inteligentes**



Fonte: <https://techcrunch.com/2018/05/14/you-can-now-try-smart-compose-in-the-new-gmail/>



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Preparação dos Textos

Processamento de Linguagem Natural

Como tratar dados de texto?



Para ilustrar como NLP utiliza textos, vamos considerar a frase abaixo do livro Dom Casmurro, de Machado de Assis:

"Uma noite destas, vindo da cidade para o Engenho Novo, encontrei no trem da Central um rapaz aqui do bairro, que eu conheço de vista e de chapéu."

Como podemos extrair as principais informações do texto acima?

Processamento de Linguagem Natural

Preparação dos textos



Antes de utilizarmos o texto com uma das técnicas de NLP é fundamental realizar algumas etapas de **preparação** dos textos para que obtenhamos o **melhor resultado**.

As etapas podem variar dependendo da origem dos dados, mas em geral consistem de:

- **Tokenização**
- **Remoção de pontuações**
- **Remoção de números**
- **Remoção de espaços extras**
- **Conversão para minúsculas**
- **Remoção de stopwords**
- **Stemização**
- **Lematização**

Vamos ver com mais detalhes cada uma dessas etapas.

Processamento de Linguagem Natural

Preparação dos textos: Tokenização



A **Tokenização** do texto consiste em segmentar o texto, ou seja, transformar o parágrafo em uma lista de palavras.

"Uma noite destas, vindo da cidade para o Engenho Novo, encontrei no trem da Central um rapaz aqui do bairro, que eu conheço de vista e de chapéu."



['Uma', 'noite', 'destas', ',', 'vindo', 'da', 'cidade', 'para', 'o', 'Engenho', 'Novo', ',', 'encontrei', 'no', 'trem', 'da', 'Central', 'um', 'rapaz', 'aqui', 'do', 'bairro', ',', 'que', 'eu', 'conheço', 'de', 'vista', 'e', 'de', 'chapéu', '.']

Algumas bibliotecas como a **Spacy** possuem diversos métodos associados a cada token e que permitem uma **análise mais detalhada de cada palavra**.

Processamento de Linguagem Natural

Preparação dos textos: Remoção de Pontuações



Preditiva.ai

A **Remoção de pontuações** consiste em eliminar todos os sinais de vírgula, ponto final, ponto de exclamação etc.

['Uma', 'noite', 'destas', ',', 'vindo', 'da', 'cidade',
'para', 'o', 'Engenho', 'Novo', ',', 'encontrei', 'no',
'trem', 'da', 'Central', 'um', 'rapaz', 'aqui', 'do',
'bairro', ',', 'que', 'eu', 'conheço', 'de', 'vista', 'e', 'de',
'chapéu', '.']

Ainda que para nós os sinais de pontuação sejam bastante importantes para extrair as ideias corretamente, nas técnicas de **NLP** normalmente eles são desprezados.

Processamento de Linguagem Natural

Preparação dos textos: Remoção de Números



A **Remoção de números** visa eliminar todos os caracteres entre 0 e 9 existentes no texto.

['Uma', 'noite', 'destas', 'vindo', 'da', 'cidade', 'para',
'o', 'Engenho', 'Novo', 'encontrei', 'no', 'trem', 'da',
'Central', 'um', 'rapaz', 'aqui', 'do', 'bairro', 'que', 'eu',
'conheço', 'de', 'vista', 'e', 'de', 'chapéu']

Ainda que neste exemplo não tenhamos números, a ideia é que os **números** podem assumir **muitos significados** diferentes e utilizá-los poderá trazer **mais ruído** para o modelo.

Processamento de Linguagem Natural

Preparação dos textos: Remoção de Espaços Extras



A **Remoção de todos os espaços extras** visa eliminar uma possível identificação de espaços como palavras:

['Uma', 'noite', 'destas', 'vindo', 'da', 'cidade', 'para',
'o', 'Engenho', 'Novo', 'encontrei', 'no', 'trem', 'da',
'Central', 'um', 'rapaz', 'aqui', 'do', 'bairro', 'que', 'eu',
'conheço', 'de', 'vista', 'e', 'de', 'chapéu']

Como nosso texto veio de um **livro**, não teremos esse e alguns outros problemas como palavras **escritas com grafia errada**.

Veremos mais adiante que a **origem do texto influencia** fortemente como a preparação dos textos deve ser realizada para obter o melhor resultado.

Processamento de Linguagem Natural

Preparação dos textos: Conversão para Minúsculas



Preditiva.ai

A **Conversão de todas as letras para minúsculas** tem como objetivo fazer com que todas as palavras iguais sejam tratadas da mesma maneira.

['**u**ma', 'noite', 'destas', 'vindo', 'da', 'cidade', 'para',
'o', '**e**ngenho', '**n**ovo', 'encontrei', 'no', 'trem', 'da',
'**c**entral', 'um', 'rapaz', 'aqui', 'do', 'bairro', 'que', 'eu',
'conheço', 'de', 'vista', 'e', 'de', 'chapéu']

Porém, os **nomes próprios, nomes de locais** e outros podem ser preservados para **manter o significado**. Por exemplo, "Engenho Novo" é o nome de um bairro do Rio de Janeiro. Fazer essa identificação de forma automática é um grande desafio para trabalhar com linguagem natural.

Processamento de Linguagem Natural

Preparação dos textos: Remoção de *Stopwords*



A **Remoção das palavras de ligação** ou ***stopwords*** consiste em eliminar palavras que são muito frequentes mas que trazem pouca informação.

Texto original

"Uma noite destas, vindo da cidade para o Engenho Novo, encontrei no trem da Central um rapaz aqui do bairro, que eu conheço de vista e de chapéu."



Texto preparado

['noite', 'destas', 'cidade', 'o',
'engenho', 'encontrei', 'trem',
'central', 'rapaz', 'bairro', 'conheço',
'vista', 'e', 'chapéu']

A lista de ***stopwords*** a ser considerada para remoção varia bastante de acordo com a **origem do texto** e o **objetivo da análise**.

Processamento de Linguagem Natural

Preparação dos textos: Stemização e Lematização



Preditiva.ai

As técnicas de **Stemização** e **Lematização** têm o mesmo objetivo: buscar a forma invariante das palavras em relação ao conceito que representam. Este é um dos processos mais complexos do pré-processamento porque envolvem profundo conhecimento linguístico.

Stemização significa obter a raiz da palavra, ou seja, eliminar flexões e sufixos adicionados as palavras. Após esse processo a raiz obtida não precisa necessariamente ser uma palavra.

Lematização significa transformar a palavra em sua **forma canônica**, ou seja:

- Substantivos e Adjetivos: singular masculino
- Verbos: infinitivo

Utilizando essas técnicas conseguimos **reduzir a variabilidade na forma escrita** das palavras e **manter os conceitos** por elas representados.

Nesta etapa é necessário **decidir por uma das transformações**, pois não é possível aplicá-las simultaneamente nas mesmas palavras.

Demonstração

Preparação dos Textos

Arquivo **1_NLP.zip** contém:

- 1_NLP.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Análise Exploratória

Processamento de Linguagem Natural

Análise Exploratória



Uma forma bastante eficaz de fazer uma **Análise Exploratória** do texto preparado é utilizando as **Nuvens de Palavras** ou **Wordclouds**.



As **palavras mais frequentes** aparecem com **maior tamanho**. Com isso é possível avaliar se alguma palavra que não faz sentido precisa ser incluída na lista de ***stopwords*** para remoção na etapa de **preparação dos textos**.

Demonstração

Análise Exploratória

Arquivo **1_NLP.zip** contém:

- 1_NLP.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Representação de Textos: *Bag of Words*

Processamento de Linguagem Natural

Representação de Textos




Agora que sabemos como aplicar as técnicas de **preparação dos textos** e realizar uma primeira **análise exploratória**, vamos para a próxima etapa que é gerar **representações desses textos**.

As **representações** nos permitem **estruturar a informação** contida nos textos em variáveis que possam ser utilizadas com outras técnicas que já aprendemos como classificação, regressão, clusterização etc.

Existem diferentes formas de **representar os textos**, algumas bastante simples e outras mais complexas. Você aprenderá as 3 mais utilizadas, na ordem de mais simples para mais complexa:

- *Bag of Words (BoW)*
- *TF-IDF*
- *Word Embedding*



Fonte: <https://towardsdatascience.com/creating-word-embeddings-coding-the-word2vec-algorithm-in-python-using-deep-learning-b337d0ba17a8>

Processamento de Linguagem Natural

Representação de Textos: *Bag of Words*



A representação ***Bag of Words*** (BoW), como o próprio nome diz, consiste em colocar todas as palavras em uma sacola, sem considerar sua sequência ou tipo, e contar sua frequência.

Ao final desse processo, cada texto se transformará em diversas variáveis, cada uma delas representando uma palavra, e seu conteúdo será a frequência com que cada palavra ocorreu no texto.

Frase 1

['noite', 'destas', 'cidade', 'o', 'engenho', 'encontrei', 'trem', 'central', 'rapaz', 'bairro', 'conheço', 'vista', 'e', 'chapéu']

Frase 2

['cumprimentou-me', 'sentou-se', 'pé', 'mim', 'falar', 'lua', 'e', 'ministro', 'e', 'acabar', 'recitando-me', 'verso']

Frase	noite	destas	cidade	o	engenho	encontrar	trem	central	rapaz	bairro	conhecer	visto	e	chapéu	cumprimentou-me	sentou-se	pé	mim	falar	lua	ministro	acabar	recitando-me	verso
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	0	0	2	0	1	1	1	1	1	1	1	1	1	1

Demonstração

Representação de Textos: *Bag of Words*

Arquivo **1_NLP.zip** contém:

- 1_NLP.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Representação de Textos: TF-IDF

Processamento de Linguagem Natural

Representação de Textos: TF-IDF



Ainda que a representação **BoW** funcione muito bem para diversas tarefas, como classificação de textos, entre suas deficiências está a de considerar simplesmente a frequência de uma palavra dentro do texto, e não ponderar se essa palavra, no contexto geral, é comum, ou seja, se ela aparece em muitos documentos.

Representação Bag of Words

Frase	noite	destas	cidade	o	engenho	encontrar	trem	central	rapaz	bairro	conhecer	visto	e	chapéu	cumprimentou-me	sentou-se	pé	mim	falar	lua	ministro	acabar	recitando-me	verso
1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	0	0	0	0	2	0	1	1	1	1	1	1	1	1	1	1

Processamento de Linguagem Natural

Representação de Textos: TF-IDF



Por esse motivo, foi proposta a representação **TF-IDF** ou ***Term Frequency-Inverse Document Frequency***. Nesta representação além da frequência da palavra no texto é considerada sua presença em todos os textos do conjunto de dados, também chamado de **corpus**.

Term Frequency

$$tf(t, d) = f_{t,d}$$

Frequência do termo t
no documento d .

Inverse Document Frequency

$$idf(t, D) = \frac{1}{| \{ d \in D \mid t \in d \} |}$$

Inverso do número de
documentos do conjunto de
dados D em que o termo t
ocorre.

TF-IDF

$$tfidf(t, d, D) = f_{t,d} \cdot \frac{1}{| \{ d \in D \mid t \in d \} |}$$

Frequência do termo
ponderada por um indicador
de quão comum esse termo é.

Demonstração

Representação de Textos: TF-IDF

Arquivo **1_NLP.zip** contém:

- 1_NLP.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Representação de Textos: *Word Embedding*

Processamento de Linguagem Natural

Representação de Textos: *Word Embedding*



Como pudemos ver anteriormente, as representações **BoW** e **TF-IDF** possuem algumas oportunidades de melhoria:

- **Dimensionalidade muito grande:** pois ela é proporcional ao vocabulário dos textos;
- **Variáveis esparsas:** poucas palavras do vocabulário inteiro estarão em uma frase ou texto;
- **Não consideram a sequência de palavras:** sabemos ser importante para contextualizar a informação;
- **Impossibilidade de transferir o aprendizado:** um novo conjunto de textos requer a reconstrução da representação.

Processamento de Linguagem Natural


Representação de Textos: *Word Embedding*



Preditiva.ai

Por esses motivos, surgiram **representações de texto mais inteligentes** chamadas de ***Word Embeddings*** que buscam exatamente:

- Representar as palavras em um **espaço dimensional muito menor** que BoW e TF-IDF, fazendo com que não existam mais as **variáveis esparsas**;
- **Considerar o contexto das palavras** analisando as demais palavras do entorno;
- **Serem reaproveitáveis** para utilização em diferentes conjuntos de textos.



Fonte: <https://medium.com/@hari4om/word-embedding-d816f643140>

Processamento de Linguagem Natural


Representação de Textos: Word2Vec




Preditiva.ai

Um dos métodos de **Word Embedding** mais utilizados é o **Word2Vec** e como o próprio nome diz, consiste em construir uma representação vetorial para cada palavra.


O Word2Vec foi proposto em 2013 por [Tomas Mikolov do Google](#) e utiliza **Redes Neurais Artificiais** para construir a representação vetorial.



Male-Female



Verb tense



Country-Capital

Processamento de Linguagem Natural


Representação de Textos: Word2Vec



Existem 2 estratégias para construir o **Word2Vec**: **CBow** e **Skip-Gram**.

Na **Skip-Gram** o objetivo do treinamento é aprender uma representação vetorial que seja boa em prever as palavras próximas da palavra treinada.

- #01: Em Deus nós confiamos todos os outros devem trazer dados
- #02: Em Deus nós confiamos todos os outros devem trazer dados
- #03: Em Deus nós confiamos todos os outros devem trazer dados
- #04: Em Deus nós confiamos todos os outros devem trazer dados
- #05: Em Deus nós confiamos todos os outros devem trazer dados
- #06: Em Deus nós confiamos todos os outros devem trazer dados
- #07: Em Deus nós confiamos todos os outros devem trazer dados
- #08: Em Deus nós confiamos todos os outros devem trazer dados
- #09: Em Deus nós confiamos todos os outros devem trazer dados
- #10: Em Deus nós confiamos todos os outros devem trazer dados



Processamento de Linguagem Natural


Representação de Textos: Word2Vec



Existem 2 estratégias para construir o **Word2Vec**: **CBow** e **Skip-Gram**.

Na **CBow** o objetivo do treinamento é exatamente o inverso do **Skip-Gram**: aprender uma representação vetorial que seja boa em prever uma palavra dado seu contexto.

- #01: Em Deus nós confiamos todos os outros devem trazer dados
- #02: Em Deus nós confiamos todos os outros devem trazer dados
- #03: Em Deus nós confiamos todos os outros devem trazer dados
- #04: Em Deus nós confiamos todos os outros devem trazer dados
- #05: Em Deus nós confiamos todos os outros devem trazer dados
- #06: Em Deus nós confiamos todos os outros devem trazer dados
- #07: Em Deus nós confiamos todos os outros devem trazer dados
- #08: Em Deus nós confiamos todos os outros devem trazer dados
- #09: Em Deus nós confiamos todos os outros devem trazer dados
- #10: Em Deus nós confiamos todos os outros devem trazer dados



Processamento de Linguagem Natural

Representação de Textos: Word2Vec



Comparando os 2 modelos, cada um tem seus pontos fortes:

Skip-Gram

- Funciona em conjuntos de dados menores
- Representa bem palavras raras

CBoW

- Mais rápido no treinamento
- Representações melhores para palavras frequentes

Como o processo de treinamento da RNA para obter as representações é bastante intensivo, é bastante comum a utilização de representações já construídas e disponibilizadas por grupos de pesquisa.

Para a língua portuguesa o [NILC - Núcleo Interinstitucional de Linguística Computacional](#) possui muitos recursos disponíveis, inclusive várias representações já treinadas com diferentes dimensões.

Para o inglês temos o [modelo treinado](#) pelo Mikolov no Google com 1,5GB de tamanho.

Demonstração

Representação de Textos: Word2Vec

Arquivo **1_NLP.zip** contém:

- 1_NLP.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py



Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP


Modelos de Classificação de Textos

Processamento de Linguagem Natural

Modelos de Classificação de Textos



Após extrairmos as características dos textos utilizando as técnicas de representação **Bag-of-words**, TF-IDF e **Word Embedding**, temos informações suficientes para desenvolver um **modelo de classificação de textos**.



Demonstração

Modelos de Classificação de Textos

Arquivo **2_NLP_Classificacao.zip** contém:

- 2_NLP_Classificacao.ipynb
- Womens Clothing E-Commerce Reviews.csv
- preditiva.py




Preditiva.ai

Dados Não Estruturados Processamento de Linguagem Natural - NLP

Hands On: Análise de Sentimentos no Twitter

Processamento de Linguagem Natural

Análise de Sentimentos COVID-19 no Twitter



Hands on

Análise o sentimento predominante nos Tweets sobre o COVID-19 e desenvolva um modelo para classificar o sentimento dos novos tweets utilizando as técnicas de NLP

Roteiro:

1. Utilize a base **Corona_NLP_train.csv** e crie uma nova variável "sentimento" apenas com as categorias "Extremely Negative" e "Extremely Positive".
2. Aplique as técnicas de **preparação dos textos** e avalie o resultado do pré-processamento.
3. Realize a **análise exploratória** por categoria da nova variável **sentimento** e ajuste o que for necessário para obter um texto limpo mas que preserve o máximo de informações.
4. Crie **representações do texto** utilizando **BoW**, **TF-IDF** ou **Word2Vec** e desenvolva modelos de classificação utilizando essas representações como *features*.
5. Foi possível identificar o **sentimento dos autores** a partir dos textos? O **desempenho** e **tempo** de treinamento dos modelos foi aceitável?

Notebook resolvido

3_Sentimentos_COVID19_NLP_Resolvido.zip



Preditiva.ai